



南京大學

研究生學位論文答辯記錄

院 系	計算機學院
專業名稱	計算機技術
研究方向	自然語言處理
學位級別	碩士
姓 名	朱博林
指導教師	程 龔 教授

2026 年 5 月 22 日

答辩时间	2026 年 5 月 22 日		答辩地点	计算机学院 421 会议室
出席委员人数	缺席委员人数	会议主席	会议秘书	记录人
3	0	瞿裕中	孙泽群	周晓
论文题目	基于公式的数值推理方法与评测研究			

论文答辩记录:

提问 1: 论文题目名为方法与评测, 但是方法特别弱, 这个方法有什么创新?

回答: 这个方法主要对于数值推理问题进行了模块化拆分。

提问 2: 论文应该第四章讲方法, 第五章再讲评测。先讲评测再讲方法有些奇怪, 难道不能评测本文方法吗?

回答: 可以评测。

提问 3: 数据的爬取有版权吗?

回答: 爬取内容是公开的网络资源。

提问 4: 第五章构建的训练集数据和前文一致, 这不是数据预泄露吗?

回答: 在第三章构建数据时划分了训练集和测试集, 在训练时使用的训练集, 测试时使用的测试集。

提问 5: 本文数据集是通过大模型进行标注的, 其他人很容易构建类似的数据集, 创新点在哪里?

回答: 除了构建的数据集之外, 本文提出的构建过程也是本文的贡献内容。该构建方法可以提供公式知识的标注, 还可以增大原有问题的难度。

提问 6: 关于第三章数据集构建过程, 使用了大预言模型进行数据标注, 这个会不会引入模型偏差? 有没有相应的人工检查, 比例是多少?

回答: 确实会有模型偏差。本文对于数据的质量保证采取了程序验证和人工验证两部分。程序验证方面, 本文使用了计算器去验证每一道题目的解题步骤计算过程是否正确, 以及最后答案是否与原问题一致。人工验证方面, 我们验证了测试集的一个关键子集, 这个子集是由各大语言模型评测后没有回答正确的问题的并集。

提问 7: 这个题目的构建是 15 至 24 年的题目, 可能会涉及大语言模型的预训练污染。

回答: 本文考虑到了这个问题并采取了相应措施, 在 3.3 节中采取了问题变换, 3.4 节采取了难度增强方案。这可以看作是对预训练带来数据污染的弥补措施。

论文答辩记录：

提问 8：对于题目的解答必须理解其中的公式吗，会不会按照模板进行计算？例如将问题中”焦耳“类似的单位换成其他表示方式是否可以正确解答？

回答：本文的方法中分多个模块处理问题，将公式的推理和数值计算完全分离。例如在公式生成模块专注于文本的公式推理，而到第二个模块，即参数识别模块才会对具体的参数进行识别理解。

提问 9：在公式库合并中合并的标准可靠吗，这个直接关系到检索增强生成和 OOD 的实验内容，如何保证合并标准的？

回答：本文合并采取了基于结构和符号的合并、基于大语言模型的语义合并以及人工检查的合并。第一步只有在公式结构一致时，例如同样为加法结构或乘法结构，并且符号一致才会合并；第二步在语义一致时才会合并；第三步由人工保证。所以整体来看还是较为可靠的。

提问 10：有没有公式错误但是最后结果答对了？准确率这一评价指标并不能正确地反映过程。

回答：从理论角度看确实可能出现应用错误的公式但是最后计算结果正确，但是从实际的样例观察来看，模型几乎不会生成一个和题目完全无关的公式。准确率这一指标确实不能完全正确反映过程，在最后的总结与展望中也提到了对于中间过程监督的研究不足。

提问 11：摘要以及总结与展望中，只是分各点阐述，没有例如”综上“的总结内容，这些要进行更改。

回答：好的。

提问 12：前面数据集构造和后文的方法是否一致？

回答：类似但是后文方法中的模型经过监督数据微调

提问 13：题目中写的是方法与评测研究，论文中的重点是数据集还是方法？应该进一步修改。

回答：数据集和方法都有，但是较为侧重数据集