

学校代码: 10284
分类号: TP399
密 级: 公开
U D C: 004.8
学 号: 522023330123



南京大學

硕士学位论文

论文题目	基于公式的数值推理方 法与评测研究
作者姓名	朱博林
专业学位类别(领域)	计算机技术
研究方向	自然语言处理
导师姓名	程龚 教授

2026 年 5 月 15 日

答辩委员会主席 瞿裕忠 教授

评 阅 人 胡伟 教授

赵一铮 副教授

论文答辩日期 2026 年 5 月 22 日

研究生签名:

导师签名:

Research on Formula-Based Numerical Reasoning Methods and Evaluation

by
Bolin Zhu

Supervised by
Professor Gong Cheng

A dissertation submitted to
the graduate school of Nanjing University
in partial fulfilment of the requirements for the degree of

MASTER

in
Computer Technology



Computer Science and Technology
Nanjing University

May 15, 2026

南京大学学位论文原创性声明

本人郑重声明，所提交的学位论文是本人在导师指导下独立进行科学研究工作所取得的成果。除本论文中已经注明引用的内容外，本论文不包含其他个人或集体已经发表或撰写过的研究成果，也不包含为获得南京大学或其他教育机构的学位证书而使用过的材料。对本文的研究做出重要贡献的个人和集体，均已在论文的致谢部分明确标明。

本人郑重声明愿承担本声明的法律责任。

签名：朱博林

日期：2026年5月15日

南京大学研究生毕业论文中文摘要首页用纸

毕业论文题目：基于公式的数值推理方法与评测研究

计算机技术 专业 2023 级硕士生姓名：朱博林

指导教师（姓名、职称）：程龚 教授

摘 要

数值推理是自然语言推理中的重要形式，对公式的应用是人类在数值推理中的基本能力。近年来，许多数值推理数据集的出现促进了数值推理的研究，但是现有数据集通常依赖于隐性数学知识，缺少相关的公式知识标注，不利于模型的训练与评估。在大语言模型进行数值推理的相关研究中，各个方法较少关注对于公式知识的运用，容易出现幻觉或错误。为了解决以上问题，本文进行了以下相关研究：

本文构建了 FormulaReasoning 数据集，该数据集是一个基于物理领域公式的数值推理数据集，共包含 5324 个问题。该数据集通过数据收集与预处理、公式标注和问题变换三个步骤进行构建。在大语言模型的辅助标注下，实现了自动化的标注流程，并对本文数据集提供了较高质量与较细粒度的知识标注。本文还开发了难度增强版本的数据集，同时还提供和数据集相关的其他资源文件。本文基于构建的数据集进行了多种方法的评测和分析，包括零样本方法、检索增强生成方法、监督微调方法和直接偏好优化方法，本文详细说明了每一种方法的具体设置和实验结果，为后续研究奠定了基础。

本文提出了一种基于公式的数值推理方法，该方法基于公式将数值推理拆分成多个子任务，使用公式生成、参数识别和数值计算三个模块进行数值推理。相比于其他方法，该方法增强了模型的推理步骤在知识层面的可解释性，降低了对每个子任务中模型能力的要求，并保障了数值计算的准确性。对比实验的结果说明了本文方法相比于其他方法的优势，能够提高 8B 以下参数的大语言模型在公式数据集上的性能表现；消融实验验证了本文方法中使用不同模型负责不同子任务的方法有效性；多公式候选实验探究了模型在公式应用上的潜力和优化空间。

关键词：公式；数值推理；数据集；评测

南京大学研究生毕业论文英文摘要首页用纸

THESIS: Research on Formula-Based Numerical Reasoning Methods and
Evaluation

SPECIALIZATION: Computer Technology

POSTGRADUATE: Bolin Zhu

MENTOR: Professor Gong Cheng

ABSTRACT

Numerical reasoning is an important form of natural language reasoning, and the application of formulas is a fundamental ability of humans in numerical reasoning. In recent years, the emergence of many numerical reasoning datasets has promoted research in this field. However, existing datasets often rely on implicit mathematical knowledge and lack relevant formulaic annotations, which hinders training and evaluation of models. Current research on large language models (LLMs) for numerical reasoning seldom focuses on the utilization of formulaic knowledge, making models prone to hallucinations or errors. To address these issues, this thesis conducts following relevant research:

This thesis constructs the FormulaReasoning dataset, a dataset for formula-based numerical reasoning in the field of physics, containing a total of 5,324 questions. The dataset is constructed through three main steps: data collection and preprocessing, formula annotation and question transformation. With the assistance of large language models in the annotation process, an automated annotation workflow has been achieved, providing high-quality and fine-grained knowledge annotations for the dataset. This thesis also develops an enhanced version of the dataset with increased difficulty, and provides additional resource files related to the dataset. This thesis conducts an evaluation and analysis of multiple methods based on the constructed dataset, including zero-shot method, retrieval-augmented generation method, supervised fine-tuning method, and direct preference optimization method. This thesis provides detailed explanations of the specific settings and experimental results for each method, laying the foundation

for future research.

This thesis proposes a formula-based numerical reasoning method that decomposes numerical reasoning into multiple sub-tasks based on formulas. It employs three modules (formula generation, parameter recognition, and numerical calculation) for numerical reasoning. Compared to other methods, this method enhances the interpretability of the reasoning steps at the knowledge level, reduces the demands on the model’s capabilities for each sub-task, and ensures the accuracy of numerical calculations. Comparative experiments demonstrate the advantages of the proposed method over others, showing its ability to improve the performance of large language models with fewer than 8 billion parameters on formula-based datasets; ablation studies validate the effectiveness of the approach, where different models are responsible for different sub-tasks; and multiple formula candidate experiments explore the model’s potential and optimization space in formula application.

KEYWORDS: Formula; Numerical Reasoning; Dataset; Evaluation

目 录

目 录	VII
第一章 绪论	1
1.1 研究背景	1
1.2 研究问题	2
1.2.1 数值推理评测	2
1.2.2 数值推理方法	3
1.3 本文内容	4
第二章 相关工作	7
2.1 预备知识	7
2.1.1 分词与词向量	7
2.1.2 大语言模型架构与预训练	8
2.2 数值推理数据集	9
2.2.1 数据内容	9
2.2.2 构建方式	10
2.3 数值推理方法	11
2.4 本章总结	14
第三章 基于公式的数值推理数据集构建	15
3.1 数据收集与预处理	15
3.2 公式标注	15
3.3 问题变换	18
3.4 难度增强	21
3.5 相关资源构建	23

3.5.1	公式库构建	24
3.5.2	增广数据构建	26
3.5.3	直接偏好优化数据构建	26
3.5.4	英文数据集构建	27
3.6	本章总结	28
第四章 基于公式的数值推理方法评测		29
4.1	评测设置	29
4.1.1	基线方法	29
4.1.2	数据集	32
4.1.3	评测指标	33
4.2	零样本方法评测	34
4.2.1	实现细节	34
4.2.2	评测结果	34
4.3	检索增强生成方法评测	38
4.3.1	实现细节	38
4.3.2	评测结果	38
4.4	模型微调方法评测	39
4.4.1	实现细节	39
4.4.2	评测结果	40
4.5	直接偏好优化方法评测	40
4.5.1	实现细节	40
4.5.2	评测结果	41
4.6	本章总结	41
第五章 一种基于公式的数值推理方法		43
5.1	方法概述	43
5.2	方法实现	44
5.2.1	基于公式的训练数据构建	44
5.2.2	基于公式的数值推理方法	45
5.3	评测设置	46

5.3.1	基线方法	46
5.3.2	数据集	47
5.3.3	评测指标	47
5.4	评测结果	47
5.4.1	对比实验	47
5.4.2	消融实验	49
5.4.3	多公式候选实验	49
5.5	本章总结	50
第六章 结论与展望		51
6.1	研究总结	51
6.2	未来展望	52
参考文献		53
附录 A 正文中涉及的提示词		67
致 谢		73

第一章 绪论

本章主要对本文的研究进行概述。在1.1节中介绍本文的研究背景；1.2节中具体阐述本文研究问题和内容；1.3节中介绍本文内容和各章的基本结构。

1.1 研究背景

数值推理是自然语言推理中的一种重要形式。随着自然语言处理和人工智能技术的迅速发展，尤其是近年来专门化数据集的出现以及大语言模型的发展，数值推理的研究取得了显著进展。

基于深度神经网络的大语言模型，如 GPT 系列（GPT-3^[1]、GPT-4^[2]等）、Qwen 系列（Qwen^[3]、Qwen2^[4]等）和 GLM 系列^[5]（ChatGLM3、GLM-4）等，已经在多个自然语言理解任务上超越了传统方法，并为数值推理带来了前所未有的表现效果。这些大语言模型拥有远超以往模型的参数量，并且在海量数据中进行了训练，使得其在处理文本信息上有着强大的能力。在大量的文本数据中学习的语义知识能够让其有效地处理文本任务，对于文本中数值计算也有较好的效果。

同时，为了推动数值推理研究，许多专门化数据集应运而生。越来越多的数据集不止局限于单步推理，更多的是包含多步运算与文本理解的数据集。这些数据集为研究人员提供了更为多样的数值推理问题，推动了大语言模型数值推理能力的评估与提升。

尽管数值推理在最近几年取得了诸多进展，但仍面临许多挑战。

从数据集角度来说，虽然有众多数值推理数据集提供多步计算问题，但它们仍然存在一定的局限性，如问题过于简单、含有较少的领域知识、缺乏详细的知识标注等。例如在 GSM8K^[6]中的一个问题：“珍妮特的鸭子每天产 16 个蛋。她每天早上用 3 个做早餐，还用 4 个给朋友们做松饼。她每天把剩下的鸡蛋以每个 2 美元的价格卖给农贸市场。那么，她每天在农贸市场赚多少钱？”。其文本理解较为容易且计算过程简单，数据集中虽然有解题过程，但是缺少更详细的知识标

注。数据集中的问题很多为标准化和简化的问题，也并未完全反映真实世界问题的复杂性。公式作为一种显式的数学知识表达形式，能够为推理过程提供重要的支持，但在现有的数值推理数据集的研究中，公式的使用和整合仍然是一个被忽视的领域。

从模型角度来说，当前的大语言模型在一些复杂的数值推理任务中仍然存在不足。例如，尽管它们能够回答简单的数学问题，但在面临需要多步推理和公式应用的任务时，往往会出现推理错误，或在缺乏清晰指导的情况下出现幻觉^[7]（即和实际情况不符），在没有明确数学知识指导时，这些问题尤为突出。现有的数值推理模型往往依赖隐式的常识性知识，缺乏明确的公式或专业知识的引导。这使得模型在推理过程中容易忽略一些关键的概念，或者在面对陌生问题时无法给出准确的答案。

研究如何在自然语言处理中实现复杂的数值推理，可以进一步提升模型在理解、推理和决策中的能力。这不仅有助于提高机器学习和人工智能的整体水平，还能拓展人工智能在更多实际场景中的应用。在教育领域，自动化的数学题目解答系统能够帮助学生提高学习效率，通过数值推理模型，系统不仅能够解答题目，还能解释解题过程，帮助学生理解数学概念；在金融领域，数值推理被广泛应用于预测股市、分析投资组合的风险、评估财务报表等方面，数值推理系统能够根据市场数据和经济指标进行复杂的数值计算，并提供决策支持；在医学领域，数值推理系统能够帮助医生分析病人的病历、医学影像和检验数据，进行疾病的诊断、治疗方案的选择等。

1.2 研究问题

1.2.1 数值推理评测

数值推理数据集是用于训练和评估机器学习模型（本文中主要为大语言模型）对于数值推理问题的理解能力和数学计算推理能力的标准化数据集合。这些数据集包含了大量的数学问题，每个问题都是带有数值信息的文本，并且要求模型进行复杂运算或多步推理的任务。

通过数值推理数据集，模型可以学习如何从自然语言或结构化文本中提取数值信息，并进行必要的数学运算。这为研究人员提供了一个统一的测试数据，

题目描述	珍妮特的鸭子每天产16个蛋。她每天早上吃3个做早餐，还用4个做给朋友们的松饼。她每天把剩下的鸡蛋以每个2美元的价格卖给农贸市场。那么，她每天在农贸市场赚多少钱？ (Janet's ducks lay 16 eggs per day. She eats three for breakfast every morning and bakes muffins for her friends every day with four. She sells the remainder at the farmers' market daily for \$2 per fresh duck egg. How much in dollars does she make every day at the farmers' market?)
解题步骤	珍妮特每天卖 $16 - 3 - 4 = 9$ 个鸭蛋。 她每天在农贸市场赚 $9 * 2 = 18$ 。 #### 18 (Janet sells $16 - 3 - 4 = 9$ duck eggs a day. She makes $9 * 2 = 18$ every day at the farmer's market. #### 18)
蕴含公式	[总量] - [消耗数量] = [剩余数量] [单价] * [数量] = [总价]

图 1-1 GSM8K 中的一个示例，数据集中仅有题目描述以及解题步骤内容

用于评估不同模型在处理数值推理问题时的准确性和效率。

目前存在许多数值推理数据集，但其在公式推理方面仍存在较多不足。例如图1-1为使用较为广泛的 GSM8K 数据集中的一个示例，问题过于简单，未能充分反映现实世界的复杂性。除此之外，虽然该问题的数据中给出了计算步骤的标注，但是并没有显式标明计算步骤背后的公式知识，而且该问题依赖隐式的常识知识，具有较少或几乎没有专业领域的知识，图中也说明了题目用到的公式内容。目前也有数据集中包含了公式，如 Math23K-F^[8]，但其公式覆盖率低，仅有一小部分题目含有公式的标注，且推理步骤较短，难以作为基于公式的数据集使用。并且在目前的研究中，数值推理相关方法在完全基于公式的数据集（尤其是专业领域和复杂场景下的公式推理数据集）上相应的评测较少。

本文针对以上问题，构建了基于公式的数值推理数据集。该数据集中的题目 100% 覆盖公式，较 Math23K-F 等数据集有着更长的推理步骤，并且是更接近现实复杂场景的物理领域题目，能够更好地评测大语言模型在公式知识上的运用能力。本文在基于公式构建的数据集上对现有的大语言模型进行了多种方法的评测，为后续的研究奠定了基础。

1.2.2 数值推理方法

数值推理方法指的是用于处理和解决涉及数值计算和推理问题的各种技术和算法。数值推理不仅是进行数学计算，还包括如何从给定的文本、数据或情境

中提取和理解数值信息，并根据这些信息进行合理的推理或决策。

数值推理方法研究初期时基于统计学或规则方法，对于复杂的自然语言难以处理，泛化性较低；随着研究不断深入，以神经网络为基础的各种方法对于数值推理问题的解决有了明显的提高；大语言模型出现之后，由于其突出的表现，目前许多关于数值推理的研究均是基于大语言模型的方法。例如常用的方法有零样本提示、监督微调、检索增强生成、强化学习等方法。

对于上述的方法，在解决数值推理问题时常常存在以下问题：缺少公式的显式指导，易出现幻觉，知识层面的可解释性较弱；对大语言模型的基模型要求较高，需要单一模型处理数值推理中的所有问题；对于数值计算的准确性无法得到保障，大语言模型以概率预测为基础的生成可能会出现计算错误。

针对以上现有研究的不足，本文提出了一种数值推理方法。该方法基于公式将数值推理拆分为公式生成、参数识别和数值计算三个模块，该方法使用明确的公式知识来进行数值推理，同时对模型的要求更低，便于提高基础能力较弱的大语言模型在公式数据集上的性能表现，还能够保障数值推理中的计算准确性。

1.3 本文内容

本文的研究内容主要针对基于公式的数值推理方法和评测的探究。本文提出了基于公式的数值推理数据集，在该数据集上本文对多个模型、多个方法进行了较为全面的评测，并且提出了一种基于公式的数值推理方法。本文的贡献总结如下：

- 本文构建了一个基于公式的数值推理数据集，为每个问题提供了细粒度的注释。该数据集和相关资源可以用于增强或评估知识引导的推理能力。其规范化的推理步骤对于步骤监督方法和公式研究具有一定意义。
- 本文不仅对各种规模的大语言模型进行了零样本方法评测，同时还进行了检索增强生成方法、监督微调方法以及直接偏好优化方法的评测，实验结果为未来的研究奠定了基础。
- 本文提出了一种基于公式的数值推理方法。该方法将数值推理以公式为基础进行任务分解，并引入公式计算器来保障计算的可靠性，进而提高模型效果。该方法对于知识监督以及多模块协作的数值推理研究具有一定意义。

本文总共六个章节，各个章节之间关联较为紧密，结构如下：

第一章为绪论，为后续研究提供理论基础。主要介绍本文的研究背景、问题概述等内容，说明了数值推理领域的发展和挑战。

第二章为相关工作，该章节为后续工作进行铺垫，便于进行对比与参考。主要介绍了包括大语言模型在内的预备知识，数值推理数据集的现有工作以及数值推理方法的现有工作。

第三章为基于公式的数值推理数据集构建，基于研究现状展开数据构建，并为下文实验提供数据基础。该章节介绍了本文构建的一个基于公式的数值推理数据集的具体流程和方法，并介绍了与本数据集相关的其他资源的构建方法。

第四章为基于公式的数值推理方法评测，基于前一章节构建的数据进行了较为全面的实验，并进一步引出下一章节方法的研究。该章节对多种大语言模型在基于公式的数值推理数据集上进行了评测，包括零样本、检索增强生成、监督微调 and 直接偏好优化方法。

第五章为一种基于公式的数值推理方法，承接上一章节的实验结果，进一步进行方法上的探索研究。该章节的方法基于公式内容，将推理和计算分离，并使用多个子任务完成数值推理，提高了参数量较小的大语言模型在数值推理上的效果。

第六章为结论和展望。该章节总结了本文的研究内容，并对未来可能的研究方向进行了探讨。

第二章 相关工作

本章介绍了与本文研究相关的工作。在2.1节中介绍了大语言模型的基本知识，在2.2节中介绍了数值推理数据集的相关工作，在2.3节中介绍了数值推理方法的相关工作。

2.1 预备知识

大模型指参数量较大（通常在十亿以上）的模型，而大语言模型则指以 GPT 系列模型为代表的在自然语言处理任务中表现优异的大规模语言模型。本文主要研究大语言模型在数值推理领域的相关内容，因此了解大语言模型的相关知识有助于理解本文的方法及实验内容。下面通过分词与词向量以及大语言模型架构与预训练两部分来介绍大语言模型相关知识。

2.1.1 分词与词向量

人类对于连续的自然语言文本可以方便地阅读或理解，但是对于计算机及相应的语言模型来说，文本是难以直接处理计算的内容，正因如此，分词技术和词向量技术应运而生。

分词是将自然语言进行划分，得到由可理解的最小单元词汇（即词元）构成的序列。早期的分词技术通常是根据规则或词典进行分词。例如，可以根据空格来进行英文的分词，或者根据预设的字典词表查找最长可匹配序列来进行分词。早期的分词方法较为简单，但无法满足对于复杂文本、词形丰富语言的分词需求，随后出现了子词分词相关技术。字符对编码（Byte Pair Encoding，简称 BPE）是一种常用的基于子词的分词算法。它通过统计语料中最常见的相邻字符的出现频率，然后将这些频繁出现的相邻字符合并成一个新的子词单元，重复这个过程直到达到预定的词汇表大小。除此之外，还有 WordPiece^[9]和 SentencePiece^[10]等基于子词的分词方法，它们使用最大似然估计的方式寻找最优的子词划分。

词向量技术可以将划分好的词元序列转变成计算机可处理的数字特征。最开始的词向量使用独热编码或基于共现矩阵的统计方法来构造每个词的词向量，该类方法缺乏对于词汇语义的特征表示且有着向量维度过高、向量稀疏等问题。Word2Vec^[11]和 Glove^[12]等方法采用神经网络来学习各个词元的特征，基于预测词元的方式优化向量表示，这样方式得到的词向量具有丰富的语义特征，具有维度较低，向量稠密等特征。上述方式很好解决了单个词元的语义信息，但是同一个词元在不同语境下可能表示不同的含义，后续便出现了基于上下文的动态词向量技术。ELMo^[13]、BERT^[14]和目前主流的大语言模型的词向量均结合了上下文，能够有效区分相同词元在不同上下文中的不同含义。

2.1.2 大语言模型架构与预训练

注意力机制 注意力机制是一种模拟人类注意力的方法，最初用于图像处理，后来被引入到自然语言领域，广泛用在模型的网络结构中。注意力机制通过对序列中的元素计算注意力分数，得出当前对于序列中各部分的注意力关注程度，进而加强模型处理上下文和长序列数据的能力。Transformer^[15]则是利用注意力机制的一种网络结构，主要包括注意力机制层、前馈网络层、残差连接层等神经网络。

大语言模型架构 许多自然语言处理模型均由上述 Transformer 结构衍生而成，大致可分为编码器、解码器、编码-解码器三种架构。目前的主流大语言模型大多采用解码器架构，相比于编码器或者编码-解码器架构的模型来说，该架构能够更好地处理生成任务。以 GPT 系列模型为例，其结构主要可以分为输入层、中间层和输出层。输入层主要接收已经分词完毕的词元序列，得到文本对应的向量嵌入；中间层则为若干 Transformer 结构的网络堆叠而成，通过注意力机制不断学习向量表示；输出层则将中间层得到的向量进行线性变换后归一化为各个词元的生成概率；最后经过不断自回归解码得到模型的输出。

大语言模型预训练 大语言模型预训练的目标是让模型获得通用的语言建模能力，学习通用的语言知识，便于应用于后续的下游任务。大语言模型预训练以无监督方式进行，通过最大化预测词元概率来捕获海量文本中的语义信息。预

训练过程通常需要海量的数据，且一般来说，模型表现与模型参数量、数据量、计算资源等条件成正向关系^[16]，并可以用形如 $L(N) = (N_c/N)^{\alpha_N}$ 的关系式表达，其中 N_c 和 α_N 均为由实验得到的常数， N 为模型参数量， L 为模型损失。在这里损失越低意味着模型表现越好，该形式的公式描述同样适用于数据量、计算资源等相关因素。

2.2 数值推理数据集

本文涉及对于数据集的构建，所以本节对数值推理数据集相关工作的介绍除了数据内容的介绍之外，还包括数值推理数据集的构建方式的介绍。

2.2.1 数据内容

数值推理在自然语言中的研究已经存在多年，许多数据集，例如 GSM8K^[6]、TSQA^[17]和 MATH^[18]，都涉及了自然语言中的数值推理。数值推理数据集也有其细分领域，例如其中一类聚焦于自然语言中数值推理研究的数学应用问题，该任务通常提供一段简短的文字（即问题），并要求生成一个算术表达式来计算答案。其代表性的数据集包括 MAWPS^[19]、Math23K^[20]、MathQA^[21]等。还有一些研究专注于特定领域中的数值推理，例如，GeoSQA^[22]专注于地理领域，STEM^[23]和 ScienceQA^[24]覆盖了科学和技术的多个学科。近年推出的 Math23K-F 和 MAWPS-F^[8]分别需要使用公式来解决 33% 和 38% 的问题。

DROP^[25]数据集中的数据对文本理解有较高要求，而对数值推理能力则要求不高。例如以下这个在数据集中的问题：“在 1362 年……约翰因其替代人质失踪，觉得自己有义务返回英国继续囚禁……1364 年，约翰二世在伦敦去世，仍保持着荣誉囚禁的身份……约翰二世重新回到囚禁中后过了多少年去世？”。其答案为“2”。其中数值推理部分仅需计算两个年份差值。另外，该数据集中仅有答案，并无详细的计算过程，更不用说详细的公式或其他知识形式的标注。

MathQA 中具有一定的过程标注，该标注由一系列预定义的运算符和操作数构成，对问题的解答流程有一定的说明，但是含有较少的语义信息和知识标注，更多的是程序化的计算过程。在大语言模型出现之前，解码器形式的数值推理模型表现较好，对于程序化格式的计算过程更容易接受；但随着模型技术的发展和

迭代，这类标注内容已经不足以满足当前主流的大语言模型的需求，当前大语言模型需要更多的语义信息和知识标注来支持过程的学习和评估。

对于其中具有较好标注信息的数据集来说，其问题往往较为简单，仅需要常识性知识即可解决，并且该类数据集中对公式知识的标注仍然存在不足。以 GSM8K 数据集中的一个问题为例：“一件长袍需要 2 卷蓝色纤维和半卷白色纤维。总共需要多少卷纤维？”。这个问题隐含了简单的常识性数学知识（例如“半”意味着除以 2），该问题可以通过这个常识解决，而无需复杂的特定领域的公式知识进行数值推理。对于 Math23K-F 和 MAWPS-F^[8]这两个数据集，尽管它们分别有 33% 和 38% 的问题需要使用公式，但它们仍然主要由简单的常识性公式组成（例如，总价 = 单价 × 数量）。目前，仍然缺乏需要特定领域公式（例如用于计算物体热吸收的物理公式）来指导复杂数值推理的数据集。

表 2-1 Math23K-F、MAWPS-F、GSM8K、MATH 和 FormulaReasoning 的统计数据

数据集	Math23K-F	MAWPS-F	GSM8K	MATH	FormulaReasoning
问题数量	23162	2373	8792	12500	5324
包含公式标注的问题数量	7750	911	无	无	5324
公式数量（公式变种数量）	51（131）	18（46）	0（0）	0（0）	272（845）
平均推理长度	1.16	1.01	3.59	未知	2.36

在数据集的内容上，本文的 FormulaReasoning 涉及初高中物理领域，其复杂的真实场景和公式的计算应用较 GSM8K 等数据集更有难度，进行难度增强后的 FormulaReasoning+ 更对大语言模型带来了新的挑战；数据集中每一个问题都进行了详细的步骤标注，每个步骤都有详细的公式和参数信息，相较于其他无公式标注的数据集或仅有少量公式标注的数据集能够给出更多的信息，提供了更好的显式知识标注。在表2-1中详细展示了本文提出的数据集和其他相关数据集的信息对比。此外，本文还提供了整合的公式库、直接偏好优化数据等资源，可以作为外部知识库来评估检索增强生成或用于直接偏好优化等方法。

2.2.2 构建方式

数值推理数据集一般由人工编写或标注，在大语言模型展现强大的语言能力之后，有些数据集也使用大语言模型来辅助生成（例如 MetaMathQA^[26]和 OpenMathInstruct-2^[27]）。

GSM8K 包含了 8500 个高质量的小学数学问题。该数据集全部由人工来创

作和标注。问题构造过程中，问题的编写者需要保持高多样性来避免创作几乎一致的问题，并且选择了涉及概念不超过小学水平的问题，每个问题不涉及显示定义变量即可解决。每个问题的解答采用自然语言，而非纯粹的数学表达式，这有利于大语言模型的学习和推理。该数据集的构建质量较高，但是题目与过程全部由人工编写使其有较高的构建成本。

MetaMathQA 和 OpenMathInstruct-2 都是基于 GSM8K 和 MATH 数据集并使用大语言模型来辅助生成的数据集。在 MetaMathQA 数据集的构建过程中，研究人员使用大语言模型对原数据集中的问题进行了多解题路径的生成，保留其中最终答案正确的解题路径，并对原问题进行了自然语言表述的改写。在 OpenMathInstruct-2 数据集的构建过程中，除了对原数据集中的问题进行解题路径的生成，还进行了新问题的生成：通过少样本提示词来让大模型进一步输出新的问题。这两个数据集主要扩充了解题路径，对原问题表述的改写以及新问题的生成没有明显提高问题的难度。

在数据集的构造上，本文的 FormulaReasoning 对公开资源爬取来保证问题和答案的真实性和有效性，使用大语言模型的辅助标注来减轻人力成本，通过问题变换和难度增强方案进一步改进原有问题。本数据集系统化的构建流程和问题处理方案可以较容易地迁移至其他领域数据集并对已有的数据进行难度上的增强和数量扩充。

2.3 数值推理方法

数值推理的研究是衡量模型推理能力的一个重要研究方向，数值推理相关方法随着模型架构不断变化。对数值推理的初期研究主要基于统计学方法，例如识别文本中的动词来进行分类并计算^[28]，或者基于问题文本来得到最可能的表达式^[29]。研究初期还有基于规则和符号的方法，例如使用大量的规则，将文本进行解析得到结构树，并根据节点类型和树状结构进行计算^[30]，该类方法通过人工设计的规则或者语义解析方法，将数值推理问题映射为可直接求解计算的数学表达式，再借助符号或数学计算引擎进行问题的解答。该方法可解释性好、计算准确，但是可扩展性较低，尤其面对复杂多样的自然语言表达时，常常难以正确解答问题。随着神经网络进一步的发展和对数值推理的研究，一些基于深度

学习的方法成为数值推理的研究重点。NC-BERT^[31]通过减轻模型对数字的关注加强推理能力的学习，还有的工作使用多个网络模块来进行问题解答^[32]，或者为神经网络添加加法减法模块来提高数值推理能力^[33]。在不断的探索和研究中，通过神经网络进行解码得到计算序列再进一步数值计算来解决数值推理问题成为了一种较为有效的方法（例如 FinQA^[34]工作和 DyRRen^[35]工作中的方法）。这类方法较其他神经网络方法有较好的计算可解释性，题目解答准确性也有一定提高，但是其训练方法较为复杂，而且也越来越难以解决难度日益增大的各类数据集集中的问题。在近年大语言模型出现之后，其强大的语言理解能力和生成能力较以往的神经网络模型而言有了显著的提高，对于大语言模型的研究便成为很多自然语言研究方向的热门研究，以大语言模型为基础的方法也成为目前数值推理领域的主流研究方向。接下来介绍一些和本文较为密切的大语言模型相关方法。

零样本方法是不给出示例样本不针对性训练，仅通过提示词来引导模型输出答案的方法。在大语言模型的早期探索中，主流推理方法采用问题到答案的直接映射，这种推理范式在一些较为简单的任务（如情感分类任务、事实性问答）上表现良好，但是涉及如数值推理这样较为复杂的领域，则难以直接回答正确，而思维链则一定程度上缓解了这样的问题。思维链的核心思想是：在生成最终答案之前，引导模型显式地产生一系列中间推理步骤，使模型的推理过程更接近人类逐步思考的过程。这一方法不仅仅提高了模型在各个任务上的表现性能，还提供了更具体的中间过程，增强了大语言模型的可解释性。在后续的研究中^[36]发现，仅通过一些特定的提示词（例如“让我们一步一步思考”），大语言模型就可以生成思维链，这样的方法为零样本的思维链提示方法。与此类似，还有相关研究引导模型生成程序作为推理步骤来回答问题^[37]。在目前大语言模型评测中，零样本的提示方法由于其低成本和高通用性成为了较为流性的模型评测提示方法。

检索增强生成（Retrieval-Augmented Generation，简称 RAG）也是大语言模型领域使用较广泛的方法之一。检索增强生成通常是“检索-生成”两阶段的生成策略。在检索阶段，利用检索器从知识库、文档库或者大语言模型生成的内容等数据源中查找与输入相关的内容，例如 RARE^[38]中使用多个大语言模型进行内容生成，再从生成内容中进行检索；在生成阶段，大语言模型除了接收原本的

输入，还接收从第一阶段检索到的相关信息，在两类信息下生成最后的输出。这一方法较好地缓解了大语言模型难以更新知识、容易出现幻觉、缺乏领域知识等问题。

监督微调是大语言模型训练对齐下游任务的重要方法^[39]。典型的大语言模型训练范式采用“预训练-监督微调”两阶段的训练方法来解决下游任务。其中预训练是大语言模型从海量无监督语料数据中对语言进行建模，监督微调则是引入有标记的监督数据，使得模型在特定任务或领域下有更强的性能和更好的表现。随着大语言模型的发展，使用大语言模型来进行数据增广也成为一个重要研究^[40]。在目前的研究中，大模型既可以用于日常对话类型的内容生成^[41]，也可以用于数值推理这类问题的生成^[42]。在数值推理领域，以大语言模型为基础的数据增广可以增强数据的多样性，一定程度上弥补真实数据不足、标签难以标注的问题。

随着对大语言模型相关研究的发展，提升输出质量和加强输出内容可控程度逐渐成为研究重点。在这一背景下，强化学习被引入大语言模型训练流程，作为继预训练与监督微调之后的重要优化阶段。传统强化学习主要关注模型和环境的交互，并在奖励反馈中不断优化自身动作策略。大语言模型的强化学习（例如 GRPO^[43]，DAPO^[44]等）将输出序列的生成过程看作决策过程，将人类反馈、其他模型或者利用规则等方式产生的评分看作奖励，以此来优化模型的性能与表现。在大语言模型强化学习中，其训练的实现常常依赖于一个奖励模型或其他的奖励来源，这些奖励模型或奖励计算方式不可避免地存在内部偏差，这会给强化学习带来进一步的噪声。直接偏好优化^[45]则采用不同的优化策略，它直接对比两个文本，通过两个文本的偏好顺序来进行优化。这个方式避免了绝对奖励带来的误差，也减轻了训练时的成本。

上述相关工作均在大语言模型上进行了改进与优化，但是缺乏显式的公式知识，推理过程常常由单一模型完成所有子任务，并且在数值推理上，仍然缺乏对于数值计算准确性的保障。本文提出的方法中以公式为基础将数值推理分解成多个子任务，降低对每个模块中模型的要求以提升总体准确率，并且引入外部计算器保障计算的可靠性。

2.4 本章总结

本章介绍了和本文相关的内容和工作。首先介绍了和大语言模型相关的知识，包括分词及词向量技术以及大语言模型网络结构。接着介绍了和本文内容密切相关的研究工作，包括数值推理领域的数据集和以大语言模型为基础的若干方法，简要说明了本文与现有研究工作的不同之处。下一章将详细介绍本文提出的基于公式的数值推理数据集的构建流程与方法。

第三章 基于公式的数值推理数据集构建

本章主要介绍基于公式的数值推理数据集 FormulaReasoning 及其相关资源的构建过程。

其中3.1节、3.2节、3.3节介绍了数据集 FormulaReasoning 的构建流程。在3.4节中介绍了增强版本数据集 FormulaReasoning+ 的构建方法。在3.5节中介绍了其他有关于 FormulaReasoning 的资源构建，包括公式库、直接偏好优化数据、增广数据，以及对该数据集英文版本的构建。

3.1 数据收集与预处理

本文从公开的网络来源爬取了涵盖中国 2015 年至 2024 年总计 18433 道初中物理考试题目。这些题目包含判断、选择、计算等多种题目类型，在爬取过程中，程序根据爬取的数据结构和字段区分不同的题目类型并且排除了选择和判断等类型题目，保留数值计算类问题。本文仅保留包含以自由文本表示答案的题目，为后续的进一步标注与检查提供帮助。此外，构建的数据集主要针对纯文本问题，所以本文还剔除了需要借助示意图或图像才能解答的题目。

收集到的每个样例均包含一段题目文本以及一段包含推理步骤的解析文本。通过识别解析文本中是否包含数值，筛选其中包含数值的题目，确保最终答案为数值形式，随后使用正则表达式从解析中抽取包含单位的最终答案。对于其中 487 道题目，正则表达式未能成功匹配结果，因此采用人工提取的方式从解析文本中提取这些题目的答案。

在完成上述预处理后，到此为止构建了一个包含 6306 道题目的初始数据集。

3.2 公式标注

公式标注步骤的目标是识别并规范初始解析中的公式，进一步校验并统一其表达格式。具体来说，题目的解题步骤可以形式化表示为若干个步骤，其中每

表 3-1 初始解析和规范化解析

初始解析： 水温的变化为 $60 - 20 = 40\text{ }^{\circ}\text{C}$。因此，水吸收的热量为 $Q_{\text{吸收}} = 50\text{ kg} \times 4.2 \times 10^3\text{ J}/(\text{kg} \cdot ^{\circ}\text{C}) \times 40\text{ }^{\circ}\text{C} = 8.4 \times 10^6\text{ J}$。假设加热过程中消耗的总电能为 $1 \times 10^7\text{ J}$，水加热器的热效率可以通过热机效率的公式计算：$\eta = Q_{\text{吸收}}/W_{\text{总}} \times 100\% = (8.4 \times 10^6\text{ J})/(1.0 \times 10^7\text{ J}) \times 100\% = 84\%$。答案：如果已知加热过程中消耗的总电能为 1×10^7，那么水加热器的热效率为 84%。 规范化解析： 1. 计算水升高的温度：$[\text{水升高的温度}] = [\text{最终温度}] - [\text{初始温度}] = 60\text{ }^{\circ}\text{C} - 20\text{ }^{\circ}\text{C} = 40\text{ }^{\circ}\text{C}$。水升高的温度 = $40\text{ }^{\circ}\text{C}$。 2. 计算水吸收的热量：$[\text{水吸收的热量}] = [\text{水的质量}] \times [\text{水的比热容}] \times [\text{水升高的温度}] = 50\text{ kg} \times 4.2 \times 10^3\text{ J}/(\text{kg} \cdot ^{\circ}\text{C}) \times 40\text{ }^{\circ}\text{C} = 8400000\text{ J}$。水吸收的热量 = 8400000 J。 3. 水加热器的热效率可以通过以下公式计算：$[\text{水加热器的热效率}] = [\text{水吸收的热量}] / [\text{总电能消耗}] \times 100\% = 8400000\text{ J} / (1 \times 10^7\text{ J}) \times 100\% = 84\%$。水加热器的热效率 = 84%。 答案 = 84%
--

一个步骤都包含一个由参数名称和运算符构成的计算公式以及对应的参数列表，参数列表中的每一个参数都有如下字段：参数名称、参数数值、参数单位和参数符号。

为了提高标注效率，本文在大语言模型的辅助下采用了由粗到细的标注流程。首先，通过提示词引导大语言模型将解析文本中的推理步骤（尤其是公式）修改为规范化形式。随后，再次提示大语言模型对规范化解析中的公式及参数进行提取，获得较为详细的标注内容。下面将详细说明这一两阶段流程。

大语言模型辅助的粗粒度标注 初始解析文本中的推理步骤缺乏统一的规范，表达也较为随意。一些公式同时混用了参数名称（例如“水的质量”）和符号（例如“ $m_{\text{水}}$ ”），也有一些解析则仅给出了对数值的计算过程，未明确标注参数名称或符号。为确保所有解析在公式表达上采用统一的形式，首先对解析进行了规范化处理，其和初始解析的区别如表3-1所示。粗粒度标注将每道题目以及对应的初始解析与答案一并提供，通过少样本提示来引导大语言模型对解析进行规范化处理，具体提示词见附录A-1。实验中人工观察到，规范化后的解析整体质量较为理想。

大语言模型辅助的细粒度标注 细粒度标注的目标是得到解题中的每个公式以及公式中每个参数的符号、数值和单位。若完全依赖人工完成上述工作，将需要投入大量的人力成本。然而，由于该过程并非开放式任务，可以通过从解析

中抽取公式来确保数值推理的准确性与一致性：一旦识别出相关公式和对应参数，便可以对每一步计算进行验证，确保其最终计算结果与对应答案一致。在此过程中，任何冗余的公式或缺失的参数都能够被检测出来。因此在这一阶段引入了大语言模型的辅助来高效完成公式的解析。在粗粒度标注的基础上，进一步通过少样本提示来要求大语言模型以表格形式给出解题的公式以及公式中每个参数的符号、数值和单位，具体提示词见附录A-2。接着通过规则检查了解析中公式格式的正确性，包括参数名称、符号或单位是否存在遗漏。如果发现大语言模型生成的规范化解析格式不规范或结果错误，将根据不同的错误类型来设计少样本提示词来定位并修正这些特定错误，例如参数缺失错误或缺失的提示词见附录A-3。为了评估每条标注结果的正确性，本文通过将数值和单位带入公式，并使用 Numbat 计算器¹ 来计算答案，与标准答案对比来判断计算是否正确。

问题： 如图所示，这是中国设计的雪龙2号科学考察破冰船。……当破冰船以恒定速度 3.6 km/h 在厚冰覆盖的水域中行驶时，破冰船所受到的阻力约为 2×10^7 N。计算此时破冰船的推进功率。 参考答案： 2×10^7 W			
公式： [推力] = [阻力] [推进功率] = [推力] × [恒定速度]			
参数表			
参数名称	符号	数值	单位
阻力	f	2×10^7	N
船的速度	v	1	m/s
解析： 1. 计算推力： 推力 = 阻力 = 2×10^7 N 2. 计算推进功率： 推进功率 = 推力 × 恒定速度 = 2×10^7 N × 恒定速度（无法找到数值）			
错误： 1. 题目中“阻力”参数的格式或数值不正确 2. 参数表终无法找到“恒定速度”参数			

图 3-1 一个已经从数据中移除的示例。

在大语言模型辅助标注过程中，有一部分题目经过多次尝试仍无法纠正，通过人工观察，其本身质量较差，例如题目信息存在错误，缺少关键推理步骤等。此类题目已从数据集中移除，在图3-1中展示了一个因题目信息不完整而删除的示例。通过大语言模型辅助标注加程序化验证的方式，本文实现了 85.95% 的公

¹ <https://numbat.dev>。Numbat 支持带物理单位的科学计算

式标准化准确率，并将有错误的问题在这一步丢弃。经过上述处理后，本文的数据集至此保留了 5420 道题目。

3.3 问题变换

FormulaReasoning 中的初始题目均来自公开可访问的网络资源。考虑到大语言模型通常在大规模语料上进行训练，而这些语料可能包含了这些公开资源，因此存在数据污染和标签泄露的风险。为了减轻这种潜在偏差并构建更严格的基准，本文对题目进行了系统的改写策略。具体而言，本文采用了“逆向变换”^[46]和“参数扰动注入”^[47]方法，为每道初始题目生成了修改后的题目，同时保持其基本推理性质不变。

逆向变换 该步骤从规范化标注好的参数表中随机选择一个已知参数，并用正则表达式匹配初始题目中所有符合该参数数值以及单位的内容，将其用占位符“[X]”替换，并将初始题目的答案添加到题目中作为解题条件。替换参数之后的 X 即代表参数对应的物理量。

随机选择替换参数的过程中，如果选择到例如“水的密度”这样的参数，那么即使不进行计算或推理，也很容易得到答案为 $1 \times 10^3 \text{kg/m}^3$ ，因为在不同题目中，水的密度总是该值。这类不依赖于具体题目而总是某个值的参数本文称为固定参数，与题目相关可变的则为非固定参数。为了保证逆向变换后依然保留题目对数值推理的要求，本文在选择参数时通过关键字筛选排除了固定参数：首先预设一个包含固定参数关键字的集合，检查所有参数，将包含关键字的参数排除，在所有非固定参数中进行随机选择进行替换操作。另外由于参数的表达形式多样，有些参数无法通过字符串匹配轻易定位和替换，例如“ $4.2 \times 10^6 \text{J/h}$ ”和“ $1 \times 10^{-3} \text{dm}^3$ ”分别可能写作“每小时 $4.2 \times 10^6 \text{J}$ ”和“1L”。为了保证在替换参数时不会错误替换其他物理量，此步骤中不得不排除此类题目。

完成逆向变换后的题目则要求求出被掩盖的参数 X 的结果。

参数扰动注入 该步骤从所有题目的参数集合中随机选择一个参数，并将该参数的名称和数值作为干扰项附加到题目中。为了确保添加的参数不会影响题目的可解性（例如，不引入同一物理量的两个冲突数值），在添加该扰动文本时，

通过预设定的关键字（例如“质量”、“温度”）匹配检测来保证所添加的参数与解答初始题目所涉及的所有参数均不同。

解题步骤的生成 对于已经变换完成的问题，初始问题中需要解答的目标变为了已知项，而初始问题中包含的已知参数变成了未知项，其解题步骤与初始题目也并不相同，这需要根据初始问题对应的解题步骤进一步构建新的解题步骤，并将其作为问题变换后的步骤标签。




图 3-2 公式推理所构成的计算图

在初始题目的解题步骤中，若干参数可以根据其在计算图中的位置分为已知参数、中间参数和目标参数。以求解参数为根节点，题目中所有已知参数为叶子节点，计算得到的中间参数则为图中的其他节点，其中的边表示任意的计算关系，以此可以得出图3-2所示的计算图。从叶子节点到根节点的计算本文称为前向推理（与初始题目的解题顺序一致），从根节点到叶子节点的计算本文称为后向推理（与初始题目的解题顺序相反），本文通过前向推理和后向推理的结合生成了问题变换后的解题步骤。具体过程如下：

在前向推理中，根据除了替换为“[X]”之外的已知参数来进行初始题目的正向计算，重复迭代正向计算步骤，直到无法得出任何新的中间参数为止。在反向推理中，则根据已知的初始问题答案和前向推理的结果，按照初始问题中的解题步骤反向计算并不断重复迭代，直至无法得出任何新的中间参数为止。完成前向推理和后向推理后，将替换的参数“[X]”以方程的形式表达出来，接着




图 3-3 问题变换后的解题步骤

利用 SymPy¹等工具来进行求解和计算，最终得到以其他参数表示的“[X]”表达式。推理得到“[X]”表达式的步骤如图3-3所示。

SymPy 在物理问题领域的兼容性有限，加上方程格式多样化，使得构建新问题的过程中部分样本难以转换，或在验证过程中，部分方程无法求解（例如 SymPy 无法处理“%”和“1000kg/t”等形式）。对于这些较为难以处理的题目，在该步骤将其移除。最终经过问题变换后的题目的数量为 5324 道。在图3-4中详细展示了数据集中的数据示例。

本文将 FormulaReasoning 划分为三个子集：训练集、同源公式测试集（Homologous Formulas，简称 Hof）和异源公式测试集（Heterologous Formulas，简称 HeF），分别包含 4524、413 和 387 个问题。在 HoF 测试集中，所有公式都出现在训练集中；而在 HeF 测试集中，每个问题至少需要一个在训练集中没有出现过的公式。这个划分旨在评估微调后的模型在新公式上的泛化能力。为了提高数据质量，本文对数据的一个关键子集进行了严格的人为审核。具体来说，在上述步骤完成后人工审查了 363 个问题（约占测试集的 45.4%），这些主要是模型预测与真实答案偏离较大的问题。

1 <https://www.sympy.org/>

问题

有一台电热水器，在其水箱中加入了50kg的水，水被电加热从20°C加热到[X]。已知水的比热容为 $C_{\text{水}} = 4.2 \times 10^3 \text{ J}/(\text{kg} \cdot ^\circ\text{C})$ 。如果加热过程中消耗的总电能为 $1 \times 10^7 \text{ J}$ ，那么水加热器的热效率是多少？如果我们已经知道上面问题的答案是 84%，那么问题中 [X] 对应的内容应该是多少？

解析

水吸收的热量可以通过以下公式计算：[水吸收的热量] = [水加热器的热效率] $\times$ [总电能消耗] = $84\% \times (1 \times 10^7 \text{ J}) = 8400000 \text{ J}$ 。水吸收的热量 = 8400000 J。
 水温升高的度数由以下公式给出：[水升高的温度] = [水吸收的热量] / ([水的质量] $\times$ [水的比热容]) = $8400000 \text{ J} / (50 \text{ kg} \times 4.2 \times 10^3 \text{ J}/(\text{kg} \cdot ^\circ\text{C})) = 40 ^\circ\text{C}$ 。水温升高 = $40 ^\circ\text{C}$ 。
 计算最终温度：[最终温度] = [水升高的温度] + [初始温度] = $40 ^\circ\text{C} + 20 ^\circ\text{C} = 60 ^\circ\text{C}$ 。最终温度 = $60 ^\circ\text{C}$ 。
 答案 = $60 ^\circ\text{C}$

参数表

参数名称	符号	数值	单位
水升高的温度	Δt	40	$^\circ\text{C}$
最终温度	$t_{\text{终}}$	20	$^\circ\text{C}$
.....			
水吸收的热量	$Q_{\text{吸}}$	8400000	J
水的质量	$m_{\text{水}}$	50	kg

图 3-4 这是一个 FormulaReasoning 中的样本示例。上面为问题和对应的推理公式与推理步骤，下方为推理公式中用到的各个参数信息。

3.4 难度增强

为了进一步提升推理复杂度，本文构建了增强版数据集 FormulaReasoning+，该版本通过构造计算表达式和附加问题，将问题重新组合成更复杂的方程组求解问题来提升问题难度。

首先，采取和上一节一致的方式对初始问题中的可变参数 X 进行掩盖，并将初始答案表示为 Y 。其次，通过调整系数构建线性表达式 $E(X, Y)$ （例如 $c_1 X + c_2 Y$ ），确保 X 与 Y 之间存在关联且加减运算时量级一致，并计算出 $v = E(X, Y)$ 的值。接着引导大语言模型生成独立物理问题 Q ，使其答案的数值为 v 。最后，根据已有内容设计了混合问题：需先求解 Q 得到 v ，结合线性表达式得到关于 X 和 Y 的等式，再通过解答初始题目，得到 X 和 Y 在初始题目中的关系等式，最后求解两个等式构成的方程组得到 X 和 Y 的结果。

该方法将数学表达式、辅助问题和初始问题相结合，通过多步推理和方程组解题增加了问题的推理难度，其中所有的问题都经过程序验证，确保符合约束并且可解答。除去构造过程中转化或验证失败的问题，最终 FormulaReasoning+ 包含 4392 个扩展问题。值得注意的是，本节的难度增强与上一节（3.3节）的问题变换是并行流程，均源自同一初始问题集合。在3.3节通过人工审核进一步保证了数据集质量，本节同样对该关键子集进行了审查。

具体难度增强过程通过以下一个具体示例详细讲解。

步骤 0：初始问题 以下面一个收集的初始问题为例：

问题：一块质量为 50 克的铝块释放了 880 焦耳的热量，温度下降至 12°C。铝块的原始温度是多少？ $[C_{\text{铝}} = 0.88 \times 10^3 \text{ J}/(\text{kg} \cdot ^\circ\text{C})]$ **答案：**32°C

步骤 1：参数掩盖 该步骤首先识别了问题中的可变参数。在这个例子中，该步骤随机选择了释放的热量（880 焦耳）作为要掩盖的参数，记作 X 。同时，将该问题的初始答案（32°C）指定为第二个未知参数 Y 。

- X ：释放的热量（880 J）
- Y ：原始温度（32 °C）

步骤 2：表达式构造 该步骤构造了一个涉及 X 和 Y 的线性表达式。为了确保数值稳定性和合理的量级，构造过程中根据参数的量级调整了系数。在这个例子中，对两个参数的量级进行了对齐，并构造了以下表达式：

$$E(X, Y) = 50 \cdot Y - 1 \cdot X$$

将数值代入后得到：

$$50 \times 32 - 1 \times 880 = 1600 - 880 = 720$$

该表达式的结果为 720。

步骤 3：辅助问题生成 接下来，构造提示词让大语言模型生成了一个独立的物理问题，其答案对应于计算结果（720），其单位是从预先设置的单位集合中随机的单位（例如牛顿）。在构造过程中本文使用 GPT-4o^[48]来生成以下辅助问题：

辅助问题：小明正在进行一项物理实验。他需要使用起重机将一个质量为 80 kg 的物体垂直向上提升，并保持恒定速度。已知当地的重力

加速度为 9.0 m/s^2 ，起重机需要施加多少力才能使物体以恒定速度上升？

该辅助问题的答案是 $F = mg = 80 \times 9.0 = 720 \text{ N}$ ，与步骤 2 中表达式的目标值一致。

步骤 4：最终合成 最后，通过固定模板将新生成的混合问题组合在一起。为了进一步增加难度，在问题中加入了一个干扰参数（例如，“某气体的热值”）。最终的问题要求模型首先解决辅助问题以找到表达式的值（即 720），然后求解一个关于 X 和 Y 的方程组，其中一个方程表示它们在初始问题中的关系，另一个方程是根据辅助问题和提供表达式决定的，在本例中，其为 $720 = 50 \cdot Y - 1 \cdot X$ 。

最终问题：一块质量为 50 克的铝块释放了 $[X]$ 焦耳的热量，温度下降至 12°C 。铝块的原始温度是多少？ $[C_{\text{铝}} = 880 \text{ J/(kg}\cdot^\circ\text{C)}]$ 上述问题的答案是 $[Y]$ 。无关参数某气体的热值为 $1.4 \times 10^7 \text{ J/m}^3$ 。在国际单位制下（温度以摄氏度表示），物理量 $[X]$ 和 $[Y]$ 对应的数值表达式 $50 \cdot Y - 1 \cdot X$ 的值与以下独立问题的结果相同：小明正在进行一项物理实验。他需要使用起重机将一个质量为 80 kg 的物体垂直向上提升，并保持恒定速度。已知当地的重力加速度为 9.0 m/s^2 ，起重机需要施加多少力才能使物体以恒定速度上升？

继承自 FormulaReasoning 的相同划分，FormulaReasoning+ 包含 3608 个训练问题，其中 HoF 测试集和 HeF 测试集分别包含 406 和 378 个问题。

3.5 相关资源构建

本节的相关资源包括公式库、增广数据、直接偏好优化数据、英文数据集四个部分。公式库是基于 FormulaReasoning 进行构建的公式资源，其可用于检索增强生成^[38]、过程监督^[49]或者蒙特卡洛搜索^[50]等相关方法；增广数据主要用于监督微调中数据增广方法的训练数据；直接偏好优化数据是用于直接偏好优化训练的数据内容；英文数据集则是对构建好的中文数据集进行英文翻译，构成中英双语数据集。

3.5.1 公式库构建

本文基于 FormulaReasoning 构建了一个公式库，为后续实验和研究提供帮助。

同一公式中的参数在不同题目情境下可能有不同的表达方式。例如，公式“[水的重力] = [水的质量] * [重力加速度]”和“[重力] = [质量] * [重力加速度]”都是在计算物体的重力。将这些公式标准化对于大语言模型的使用非常有帮助，尤其是在检索增强生成等方法中，可以避免因将不同的公式表达视为不同公式而导致的长尾分布问题。

本文将公式库的构建过程划分为三个步骤：基于符号的公式合并，基于语义的公式合并，人工审核。在表3-2中展示了公式的初始数量以及每一步合并后剩余的公式数量。

表 3-2 在每一步合并步骤之后公式数量的变化

步骤	# 公式数量
合并之前	12906
在基于符号合并之后	1163
在基于语义合并之后	439
在人工审核之后	272

基于符号的公式合并过程是通过比较公式的结构和符号实现的。在物理学中，物理量通常由特定符号表示。例如，物体的质量通常用 m 表示，物体的密度常用 ρ 表示。下标用于指明物理量对应的具体对象，如 $\rho_{\text{水}}$ 表示水的密度。符号的特定表示和公式的计算结构是公式合并的基础，以下示例说明如何判断两个公式是否具有相同的结构：公式 $f_1 : a_1 = (b_1 + c_1)/d_1$ 、 $f_2 : a_2 = (b_2 + c_2)/d_2$ 和 $f_3 : b_1 = a_1 * d_1 - c_1$ 具有相同的结构，因为 f_2 可以通过重命名参数从 f_1 推导得到，而 f_3 则可以通过计算结构的变换从 f_1 得到。

因此，对于每对公式，首先计算每个公式的所有可能的结构变体，获得该公式的全部变体构成的集合。然后，比较两集合中公式的结构，判断两个公式是否具有相同结构。如果结构相同，再检查其符号（去掉下标）是否一致。若一致，则认为这两个公式可以合并。合并公式时，对于两个公式同样位置结构的两个参数，保留其中名称较短的参数，具体示例如图3-5所示。基于这种符号规则的合并后，公式库中的公式数量从 12906 减少至 1163。

公式 f0 文本表示: [体积] = [质量] / [密度] 公式 f0 符号表示: $V = m / \rho$	检查能否与 f0 公式合并: ①公式结构 ②公式符号
公式 f1 文本表示: [温度变化] = [末温] - [初温] 公式 f1 符号表示: $\Delta t = t_{\text{末}} - t_{\text{初}}$	f0 结构: $a = b / c$ f1 结构: $x = y - z$ ↓ 结构不同无法转化 
公式 f2 文本表示: [电压] = [电阻] * [电流] 公式 f2 符号表示: $U = R * I$	f0 结构: $a = b / c$ f2 结构: $x = y * z$ ↓ 结构可以转化 f0 符号: $V = m / \rho$ f2 符号: $R = U / I$ ↓ 符号不一致 
公式 f3 文本表示: [水的质量] = [水的密度] * [水的体积] 公式 f3 符号表示: $m_{\text{水}} = \rho_{\text{水}} * V_{\text{水}}$	f0 结构: $a = b / c$ f3 结构: $x = y * z$ ↓ 结构可以转化 f0 符号: $V = m / \rho$ f3 符号: $V_{\text{水}} = m_{\text{水}} / \rho_{\text{水}}$ ↓ 符号一致 

图 3-5 基于符号的公式合并具体举例

在基于符号的公式合并过程中,并未利用参数名称中的语义信息。因此,下一步是基于参数名称的语义信息进行公式合并。

例如,在符号规则合并阶段如果存在未被合并的两个公式“[密度] = [质量] / [体积]”和“[水的密度] = [水的质量] / [水的体积]”,则这两个公式应该合并。通过参数名称中的语义信息即可识别出此类可合并的公式:“密度”与“水的密度”在语义上是相似的,意味着公式有可以合并的可能。

具体而言,对于结构相同的公式,将公式中相同位置的每一对参数进行分词处理¹,得到两个参数分别对应的分词集合。当两组分词集合存在重叠时,认为这两个参数在语义上存在关联,从而将对应的两个公式作为合并候选。这种方法可以识别出一组潜在可以合并的公式对,然后通过大语言模型对每一对公式进行详细评估以决定是否合并公式,具体提示词可见附录A-4。经过这一步处理后,公式库中的公式数量从 1163 减少至 439。

在完成上述合并过程后,本文还对结果进行了人工检查,纠正了合并过程中出现的错误,并手动合并了被大语言模型遗漏的公式。在此过程中,两名人工志愿者对人工审核与修正的结果进行了交叉验证。最终,通过合并公式得到了一个由 272 个独立公式组成的统一公式库。

1 本文在该步骤使用了 jieba: <https://github.com/fxsjy/jieba>。

3.5.2 增广数据构建

数据增广指的是在不额外获得真实标注数据的前提下，通过对已有数据进行变换或生成，构造出与真实数据相似但形式或数据分布上更多样的新样本，从而扩展训练数据分布，提高模型的稳定性和泛化性等性能。本文将通过数据增广构建的数据称为增广数据。

表 3-3 生成数据示例

生成的初始问题： 小明从超市买回一袋大米，质量为 10kg。已知大米的比热容为 $2.9 \times 10^3 \text{J}/(\text{kg} \cdot ^\circ\text{C})$，若将这袋大米从 20°C 加热到 100°C，求大米吸收的热量。 生成的初始解析： 1. 计算大米温度变化量: $[\text{大米温度变化量}] = [\text{末温}] - [\text{初温}]$。算式 $= ((100)^\circ\text{C}) - ((20)^\circ\text{C}) = 80^\circ\text{C}$。 大米温度变化量 $= 80^\circ\text{C}$ 2. 计算大米吸收的热量: $[\text{大米吸收的热量}] = [\text{大米的比热容}] \times [\text{大米的总质量}] \times [\text{大米温度变化量}]$。算式 $= ((2.9 \times 10^3) \text{J}/(\text{kg} \cdot ^\circ\text{C})) \times ((10) \text{kg}) \times ((80)^\circ\text{C}) = 2320000 \text{J}$。 大米吸收的热量 $= 2320000 \text{J}$ 答案 $= 2320000 \text{J}$

本文依靠大语言模型（GLM-4^[5]）来进行增广数据资源的构建。首先，使用预先设置的模板随机生成 17000 个提示词，每个提示词中包含从训练集中抽取的五个示例，每个示例都包括问题和解题过程，在提示的末尾，要求大语言模型生成第六个问题对。该步骤生成的初始问题如表3-3所示。然后，本文对生成的公式进行了标准化处理，并对问题做了问题变换，除了没有进行人工审核外，其余步骤与3.1至3.3节的步骤一致。最后，使用 Numbat 检查大语言模型生成的数据中的计算过程是否正确，并丢弃了计算错误的数据。在经过上述步骤后，该构建流程最终保留了大约 2500 个问题，得到的增广数据的数据格式以及标注内容与数据集中的问题一致，参考图3-4所示。

在本文中，该数据仅在数据增广相关实验中使用，FormulaReasoning 及其增强版 FormulaReasoning+ 数据集中不包含由模型生成的题目。

3.5.3 直接偏好优化数据构建

本文将蒙特卡洛树搜索方法应用于 FormulaReasoning 训练集中的初始问题来生成用于直接偏好优化的偏好数据。该过程将推理步骤作为树中的节点，并使用生成模型（本文使用 DeepSeek-R1-Distill-Qwen-7B^[51]模型）对节点进行扩展。

每一个子节点相较其父节点都会多包含一步推理步骤。根节点不包含任何推理步骤，仅包含初始问题本身。当模型生成了终止标记或当前问题已经被成功求解时，即视为到达终止状态。整个生成过程由过程奖励模型（本文使用 Qwen2.5-Math-PRM-7B^[52]）进行引导，将过程奖励模型给出的评分作为奖励信号用于更新树中各个节点的价值。

在生成过程结束后，每个问题都会对应生成一棵搜索树。树中的每个节点包含截至该节点所生成的全部推理步骤，以及这些推理步骤对应的过程正确性评分。路径的整体得分通过从根节点到终止叶节点之间所有节点得分的平均值来计算。本文除了由过程奖励模型给出的评分外，还考虑了每条路径给出的最终答案与真实答案是否一致。本文基于上述的评分规则，在每棵树中识别出最优路径与最差路径。由于搜索迭代次数有限，部分叶节点可能并未达到终止状态，因此这些叶节点及其对应的路径不会被纳入后续使用。

为了进一步确保生成的偏好数据中包含充分的公式知识信息，本文还对生成结果进行了额外筛选。具体而言，对于每一个样本，同时检查其最优路径和最差路径，如果在这两条路径中均未体现出显著的公式知识使用，则该样本将被直接丢弃。本文采用了一种基于规则的模板匹配方法来识别推理过程中是否使用了公式知识。该模板与生成阶段所使用的提示词示例（见附录A-5）保持一致，其形式为包含“[{参数}]”的表达式。通过这一筛选步骤，能够确保最终用于直接偏好优化的偏好数据在推理质量和公式知识覆盖方面均具有较高的可靠性。

3.5.4 英文数据集构建

在翻译过程中，本文使用大语言模型（本文为 GPT-4o）进行翻译，逐步将中文题目、各个参数等内容翻译为英文，在附录A-6中展示了问题和参数对应的翻译提示词。

为评估翻译质量，本文还由人工翻译了 50 道题目作为对照，并使用 Qwen 系列模型分别计算大语言模型翻译版本与人工翻译版本的困惑度。具体而言，本文采用 Qwen2.5-72B-Instruct^[53] 模型进行评估，得到的大语言模型翻译与人工翻译的困惑度分别为 6.28 和 7.26。这些结果表明，当前的英文版本在流畅性方面保持了较为合理的水平。除此之外，本文还对抽样的 50 道题目的中文版本与其英文翻译版本进行了人工对比，结果发现不存在会影响题目作答的翻译错误。

3.6 本章总结

本章详细介绍了基于公式的数值推理的数据集 **FormulaReasoning** 以及其他相关资源的构建过程。构建 **FormulaReasoning** 包括数据收集与预处理，公式标注，问题变换三个过程；增强版 **FormulaReasoning+** 替换了问题变换的处理过程，用生成辅助问题和方程组的方式来增强初始问题的难度；在 **FormulaReasoning** 上抽取公式和参数，使用符号合并、语义合并、人工校验来完成对于公式库的建立；以大语言模型为生成工具，构建增广数据；以蒙特卡洛树为基础，构建直接偏好优化数据；在中文数据集上进行翻译和校对来构建英文数据集。下一章将介绍主要在该数据集上进行的一系列评测实验。

第四章 基于公式的数值推理方法评测

本章介绍了关于公式推理数据集的方法评测。在4.1节中展示了基本的评测设置，在4.2至4.5节分别展示了零样本方法、检索增强生成方法、模型微调方法、直接偏好优化方法的评测细节与结果。

4.1 评测设置

本节介绍基于公式的数值推理方法评测的评测设置，包括各个评测实验的基线方法，每个实验所进行评测的数据集，各个评测实验所用到的评测指标。

4.1.1 基线方法

由于在大语言模型出现之前的方法相比于大语言模型为基础的各种方法而言能力与泛化性较低，本文主要针对各类大语言模型以及相关方法进行评测与实验。另外本文还提供了在 `FormulaReasoning` 上的人类表现，以此作为参照和对比，展示模型与人类的差异。

零样本方法 零样本方法指模型在没有见过示例的情况下做出回答。零样本的思维链方法（Chain of Thought，简称 CoT）^[36]首先将输入文本利用分词器对文本编码，再通过大语言模型进行文本生成。在该过程中，输入文本中的提示词显式要求模型进行中间步骤的思考，使得模型输出内容分步骤进行，直至模型生成最终答案或停止生成。本文还进行了零样本的程序提示词方法（Program of Thought，简称 PoT）^[37]的评测。该方法与上述思维链方法的不同在于，提示词中要求生成代码而非自然语言，通过执行模型输出的代码来获得最终输出。这一方法减弱了模型对于计算的要求，但是对于模型的代码能力要求较高。

检索增强生成方法 检索增强生成方法是一种结合外部知识检索与语言模型生成的混合技术，分为检索和生成两阶段。本文的检索增强生成方法中，检索的

目标是根据输入文本，从公式库中检索出相关的若干个公式；而生成的过程则是根据输入文本以及从检索阶段得到的公式生成输出文本。

本文检索器（即检索阶段）分为三部分：输入文本向量嵌入，公式向量嵌入，输入文本与公式的相似度分数计算。

在输入文本向量嵌入部分，使用分词器将输入文本转化为词元编码序列（这一过程使用的分词器和接下来的编码器相匹配），再将转换为词元编码的序列通过编码器得到输入的向量表示：

$$\begin{aligned} X_{input} &= \text{Tokenizer}(X_{text}) \\ h_{input} &= \text{Encoder}(X_{input}) \\ h_{cls} &= h_{input}[0] \end{aligned} \quad (4-1)$$

本文所使用的编码器将文本编码成为向量后，其首词元即“[CLS]”词元对应的向量有着特殊的含义，通常表示句子的整体信息内容，在一些文本分类任务中常常使用此词元对应的向量来做分类。考虑到这一点，本文也使用该词元对应向量来代替输入文本的向量做后续检索。

虽然输入文本为自然语言，可以很好地通过文本语言相关的编码器模型进行编码，但是本文的公式与自然语言不同，除了公式中的参数名称，还涉及公式计算的运算符号，这一特点使得通过预训练的语言编码器得到的公式编码并不能较好地编码公式的语义和计算特征。考虑到这一特点，本文对公式的向量嵌入部分采用了随机初始化的嵌入层网络，并在后续的训练中逐步形成对每一个公式的具体向量表示。

输入文本与公式的相似度分数由以下公式进行计算：

$$\begin{aligned} \text{sim}(h_{input}, h_{formula}) &= \frac{\hat{h}_{input} \cdot \hat{h}_{formula}^T}{\tau} \\ \hat{h}_{input} &= \frac{h_{input}}{\|h_{input}\|_2}, \hat{h}_{formula} = \frac{h_{formula}}{\|h_{formula}\|_2} \end{aligned} \quad (4-2)$$

其中 $h_{formula}$ 代表公式的向量表示，其维度与上文中文本的向量维度一致。相似度计算首先对文本向量和公式向量进行 L2 归一化，确保两个向量具有相同的尺度，保证训练和推理的稳定。本文使用两个向量的余弦相似度来作为公式检索的

基础，两向量计算之后除以温度系数 τ 以平滑计算所得分数的分布。

该检索器使用批次内的对比学习^[54]来进行优化，其核心思路是：将同一批次数据中的文本与对应的一组公式进行匹配，如果公式和输入文本相关，其相似度应该尽可能高，如果公式和输入文本无直接关系，其相似度应尽可能低。以该损失函数来进行优化：

$$\mathcal{L} = -\frac{1}{B} \sum_{1 \leq i \leq B} \log \frac{\exp(\text{sim}(h_{cls}^i, h_{formula}^i))}{\sum_{1 \leq j \leq B} \exp(\text{sim}(h_{cls}^j, h_{formula}^j))}. \quad (4-3)$$

其中， B 为批次大小， h_{cls}^i 为第 i 个样本的 “[CLS]” 词元向量， $h_{formula}^i$ 为第 i 个样本对应的公式。

检索器在推理阶段相对简单，不需要进行优化和损失计算，仅需要计算出输入文本和各个公式的相似度得分，按照得分顺序依次排列即可得出公式与现有文本的相关性排序，取前若干个作为检索结果即可。

生成阶段将输入文本和检索阶段得到的公式进行拼接，得到包含公式的输入，其余可认为与零样本评测方法一致。

模型微调方法 模型微调方法是指在预训练模型的基础上，通过使用特定任务的标注数据调整模型参数，使模型适配目标任务的技术范式。本文对不同模型采用了不同的微调方式，对于参数量较小的模型（例如 1.5B）采用全量微调的方式，对于参数量较大（例如 7B）的模型采用 LoRA 微调的方式。

全量微调是通过更新模型的所有参数，使整个模型结构完全适应新任务的优化方式，其优化目标为：

$$\hat{W} = \arg \min_W \mathcal{L}(f(x; W), y) \quad (4-4)$$

其中 W 为大语言模型中的权重矩阵（例如注意力层、前馈网络层等）， x 为模型输入， $f(x; W)$ 为模型输出， y 为标签， $\mathcal{L}$ 为损失函数。

LoRA 是一种高效的参数微调方式，核心原理是通过低秩分解矩阵来模拟模型的参数变化，这样就可以仅更新低秩矩阵而非全部参数，对应的 LoRA 的优化

目标则变为：

$$\hat{A}, \hat{B} = \arg \min_{A, B} \mathcal{L}(f(x; W + AB), y) \quad (4-5)$$

其中以 $A \in R^{d \times r}$ 和 $B \in R^{r \times d}$ 表示两个低秩矩阵， r 为低秩矩阵的秩， d 为模型对应的权重矩阵的维度。

数据增广方法是在数据层面进行调整以优化模型微调后表现的方法：在训练数据上加入增广数据，用和上述一致的微调方式即可提高模型表现。该评测中使用数据的具体构建过程可见3.5.2节。

直接偏好优化方法 直接偏好优化是强化学习中的一种方法，与其他强化学习不同，该方法采用对比损失来进行学习，通过数据的偏好信息替代其他强化学习中的奖励信息。该方法所需的训练数据除了输入 x 之外，还需要一对偏好输出 y_w 和 y_l ，其中 y_w 表示希望模型更倾向输出的内容，而 y_l 则表示希望模型更倾向于拒绝的内容。

直接偏好优化的损失函数如下：

$$\mathcal{L}_{DPO} = -\mathbb{E}_{(x, y_w, y_l) \sim D} [\log \sigma(\beta \log(\frac{\pi(y_w)}{\pi_{ref}(y_w)}) - \beta \log(\frac{\pi(y_l)}{\pi_{ref}(y_l)}))] \quad (4-6)$$

其中 β 表示控制优化敏感度的超参数， π 表示待优化的大语言模型， π_{ref} 表示参考模型，通常是预训练后未优化的模型， σ 表示 sigmoid 函数。该优化目标鼓励模型在输出内容时相比参考模型更倾向于输出 y_w ，而相比参考模型更倾向于拒绝 y_l 。

4.1.2 数据集

在本文中，评测实验涉及多个数据集。具体来说，零样本方法的评测主要基于 FormulaReasoning 和其对应的增强版本 FormulaReasoning+ 这两个数据集，其详细构建过程和数据集内容可以参考第三章。对于其他方法的评测，则主要基于 FormulaReasoning 数据集。除此之外，为了验证直接偏好优化方法的有效性，在该实验中除了 FormulaReasoning 数据集外，还在以下多个数据集上进行了实验，验证了通过公式偏好数据所带来的准确性提升与泛化能力：GSM8K^[6]、MATH^[18]、SVAMP^[55]、Gaokao2023-en^[56]。这些均为数值推理领域的数据集，涵

盖了多种题目类型与不同的题目难度。

4.1.3 评测指标

本文的评测涉及准确率以及过程奖励模型分数两个指标。

准确率指标通常用于衡量模型输出与期望结果之间的匹配程度。在数值推理任务中，准确率指标主要评估模型的推理结果是否正确，并给出一个定量的分数来表示模型在解决问题时的效果。

具体来说，对于每一个样本，利用正则表达式提取模型输出中的答案字段，将答案字段与标准答案进行对比，如果相同则记为 1，不同则记为 0。在答案对比时，由于 FormulaReasoning 的任务所需要的答案不仅包括数字，还包括物理单位，本文选择使用 Numbat 进行答案的对比，该方式可以对不同形式的单位及数字进行可靠的比较。考虑到计算题并不全为整数计算，计算过程中可能产生计算误差，因此在评估时使用了宽松的比较方案：如果模型输出答案和标准答案相差在 1% 以内即视为答案相同。对于 FormulaReasoning+，该增强版本中的问题需要求解两个未知参数，对于每个样本，将两个未知参数的求解结果均进行上述比较，两个结果均和对应答案相同才记为 1，否则记为 0。将所有样本记录得分进行平均得到最后数据集的准确率。

为了评估完整推理步骤的质量，本文还使用了过程奖励模型（Process Reward Model，简称 PRM）的评分来评估大语言模型生成的推理步骤。评估采用 PRM 评分而不是严格的公式匹配，是因为基于公式的问题中的有效推理路径通常不是唯一的，不同的公式组合也能得出正确答案；并且同样含义的公式往往有不同的形式与表达，这会给过程评估带来困难。

PRM 分数的评估有两种设置：单步和多步。单步评估使用 PRM 对整体输出进行评分，而多步评估则将输出划分为多个步骤，分别对每个步骤进行评分，最后取平均值作为最终得分。这里使用了 Qwen2.5-Math-PRM-7B^[52]作为 PRM 评分模型。

4.2 零样本方法评测

4.2.1 实现细节

对于 CoT 方法, 本文按照相关工作^[36]的做法, 将“让我们一步一步思考”融入到零样本提示中, 以引导大语言模型生成推理步骤。该提示词示例见附录A-7。对于 PoT 方法, 本文提示大语言模型生成代码并用指定变量存储答案, 通过正则表达式提取其中的代码内容并执行代码得到答案, 提示词示例见附录A-8。

本文在包括成本较低的小规模模型 (如 ERNIE-4.5-21B-A3B^[57]、Gemma-3n-E4B-it^[58]、GPT-oss-20B^[59]) 以及高成本的大语言模型 (如 GPT-4o^[48]、GLM-4-plus^[5]、Qwen3-235B-A22B^[60]、DeepSeek-R1^[51]、o3-mini^[61]和 GPT-5^[62]) 在内的多种模型上进行了实验。

实验通过 DeepSeek 的 API¹访问了 DeepSeek-R1, 使用阿里巴巴百炼平台²访问了 Qwen 系列模型, 通过智谱-AI 的 API³访问了 GLM-4-plus, 其他模型则通过 OpenRouter⁴访问, 实验过程将温度参数设置为 0 以尽可能保持模型输出的稳定性, 并将最大输出长度设置为 1024, 其余参数均使用默认的超参数设置。

4.2.2 评测结果

如表4-1所示, 该实验评估了多种不同的大语言模型。根据表格结果的分析, 模型的表现与参数规模和架构设计之间存在相关性。例如, 大规模模型 (如 DeepSeek-R1 和 GPT-5) 在 HoF 和 HeF 指标上均取得了超过 88% 的优异成绩。然而, 较小规模的模型表现差距明显, 像 Gemma-3N-E4B-it 等架构的准确率低于 15%。值得注意的是, 尽管具有强大的能力, 像 GPT-4o (67.50%)、GLM-4-plus (62.63%) 和 Qwen3-235B-A22B (82.25%) 等先进的大规模模型, 仍然落后于人类表现 (92.03%)。这一差异表明, 虽然参数规模的扩展带来了一定的表现提升, 但对于参数量较小的模型仍具有相当大的优化潜力。未来的研究应针对相对较小规模的模型进行架构调整和训练策略的探索, 这对于在计算资源受限的实际部署场景中至关重要。

1 <https://api-docs.deepseek.com/>

2 <https://bailian.console.aliyun.com/>

3 <https://open.bigmodel.cn/dev/api/normal-model/glm-4>

4 <https://openrouter.ai/>

表 4-1 CoT 方法下大语言模型在中文数据集上的准确率结果

模型	FormulaReasoning			FormulaReasoning+		
	HoF	HeF	均值	HoF	HeF	均值
ERNIE-4.5-21B-A3B	66.34	67.96	67.12	6.89	6.08	6.48
Gemma-3n-E4B-it	14.04	14.47	14.25	0.99	1.32	1.16
GPT-oss-20B	85.96	82.95	84.50	59.36	57.41	58.38
GPT-4o	69.49	65.37	67.50	15.27	17.72	16.50
GLM-4-plus	61.74	63.57	62.63	17.98	16.67	17.32
Qwen3-235B-A22B	80.63	83.98	82.25	78.08	77.78	77.93
DeepSeek-R1	88.62	91.47	90.00	83.99	80.42	82.20
o3-mini	92.01	89.66	90.87	73.89	73.96	73.93
GPT-5	92.01	92.76	92.37	76.11	73.28	74.69
人类表现	93.49	90.47	92.03	-	-	-

在表4-1中还展示了 FormulaReasoning+ 上的结果，所有模型的表现都有所下降，其较低的准确率说明了扩展数据集的难度有所增加。值得注意的是，GPT-4o 和 GLM-4-plus 的准确率分别急剧下降至 16.50% 和 17.32%。即便是 GPT-5 的准确率也下降了 17.68%，这凸显了更复杂推理任务所带来的挑战。

表 4-2 CoT 方法下大语言模型在英文数据集上的准确率结果

模型	FormulaReasoning			FormulaReasoning+		
	HoF	HeF	均值	HoF	HeF	均值
ERNIE-4.5-21B-A3B	63.20	56.85	60.13	7.39	9.26	8.33
Gemma-3n-E4B-it	2.66	2.84	2.75	2.71	2.65	2.68
GPT-oss-20B	86.20	84.75	85.48	53.45	57.67	55.56
GPT-4o	75.79	74.94	75.38	14.53	12.43	13.48
GLM-4-plus	75.79	68.73	72.37	17.73	20.11	18.92
Qwen3-235B-A22B	62.47	66.67	64.50	77.34	77.51	77.43
DeepSeek-R1	87.17	87.60	87.38	76.85	79.37	78.11
o3-mini	84.02	82.17	83.13	68.23	68.52	68.38
GPT-5	88.38	88.89	88.63	71.43	69.58	70.51

在表4-2中展示了带有 CoT 提示的大语言模型在英文版本 FormulaReasoning 数据集上的评估结果。大规模模型（如 GPT-5 和 DeepSeek-R1）在 HoF 和 HeF 指标上均取得了超过 87% 的优异成绩。然而，较小规模的模型表现差距依然较为明显，像 Gemma-3n-E4B-it 等架构的准确率较低。除此之外还发现，由于在英语版本中存在遵循指令的问题，Gemma-3n-E4B-it 和 Qwen3-235B-A22B 的表现较其在中文版本中的结果有所下降，这些模型未能按照提示中指定的要求输出

所需的单位。值得注意的是，尽管 GPT-5（88.63%）具备令人印象深刻的能力，但它仍然落后于人类表现（92.03%，如前中所述），差距为 3.4 个百分点。其他先进的模型，如 GPT-4o（75.38%）和 GLM-4-plus（72.37%），与人类表现的差距更大。

在英文版本的 FormulaReasoning+ 上，也普遍存在性能下降的趋势。像 GPT-4o（从 75.38% 降至 13.48%）、o3-mini（从 83.13% 降至 68.38%）和 GPT-5（从 88.63% 降至 70.51%）等模型的表现都有显著下降。这也验证了扩展版 FormulaReasoning+ 成功引入了更高的复杂性，为评估大语言模型的推理能力提供了更为严格的基准。

在中文和英文数据集上，模型的表现相似，这表明本文提出的数据集在英文上能够提供和中文版本一致的评估效果，侧面反映出本文对英文数据集的构建是可靠且高质量的，为跨语言的数据评测提供了基础。

表 4-3 CoT 方法下大语言模型在中文 FormulaReasoning 数据集上的 PRM 分数结果

模型	单步			多步		
	HoF	HeF	均值	HoF	HeF	均值
ERNIE-4.5-21B-A3B	0.7753	0.7582	0.7668	0.8695	0.8711	0.8703
Gemma-3n-E4B-it	0.3695	0.3660	0.3678	0.7366	0.7360	0.7363
GPT-oss-20B	0.5704	0.5203	0.5454	0.5738	0.5266	0.5502
GPT-4o	0.6150	0.5583	0.5867	0.8655	0.8444	0.8550
GLM-4-plus	0.6728	0.6591	0.6660	0.8726	0.8738	0.8732
Qwen3-235B-A22B	0.6502	0.6476	0.6489	0.7946	0.7996	0.7971
DeepSeek-R1	0.7395	0.7393	0.7394	0.7603	0.7535	0.7569
o3-mini	0.7537	0.7556	0.7547	0.8104	0.8032	0.8068
GPT-5	0.8196	0.8249	0.8223	0.8196	0.8248	0.8222

表4-3展示了各个大语言模型的 PRM 分数。相较于准确率来说，各个模型的结果分布更为集中，各模型的得分差距更小。这种评估方式能够更多关注解题的中间过程，而非只关注最终结果，能够更好地反映中间步骤的可靠性。但是此评估方法也有局限性，它使用了其他的大语言模型作为评分模型，这可能会给结果带来一定的偏差，在未来研究中应当探究更明确可靠的中间过程评估方式。

表 4-4 大语言模型在 CoT 和 PoT 方法上的结果

模型	HoF	HeF	均值
GPT-4o（CoT）	69.49	65.37	67.50
GPT-4o（PoT）	54.72	41.34	48.25

模型 GPT-4o 使用 CoT 方法与 PoT 方法的结果如表4-4所示：CoT 的表现优于 PoT。一种可能的原因是，PoT 的有效性可能受到大语言模型的语言能力和编码能力的混合影响，而 CoT 仅与语言能力相关。此外，对于具备强大计算能力的大语言模型，通过 Python 代码进行数值计算的优势可能会被削弱。由于 PoT 方法在该实验中相较于 CoT 方法的表现较差，这也反映了模型在程序上下文中对于准确应用公式所面临的挑战。因此，在 FormulaReasoning 上，当前较强能力的大语言模型的瓶颈可能主要在于它们应用公式的能力，而非计算能力。

问题

有一台手持滚刷式雪地清扫机，质量为150千克（ $g = 10 \text{ N/kg}$ ）。当不清除积雪时，它的行驶功率为200 W；清除积雪时，行驶功率为3 kW。最大行驶速度为1 m/s。当雪地清扫机以最大速度行驶并清除1公里的积雪时，消耗了0.3千克燃料。求雪地清扫机释放的热量是多少？（补充：燃料的热值为 $4 \times 10^7 \text{ J/kg}$ ；雪地清扫机所做的功为[X]；）雪地清扫机与地面的接触面积为 0.1 m^2 。如果我们已经知道上述问题的答案是 $9 \times 10^6 \text{ J}$ ，那么[X]应该是多少？

模型输出（Qwen-Max错误使用物理公式）

.....省略.....
 1. 计算燃料释放的总热量：[总热量] = [燃料质量] $\times$ [热值] = $0.3 \times 4 \times 10^7 = 1.2 \times 10^7 \text{ J}$ 。
 2. 计算雪地清扫机所做的功：[总功] = [释放的热量] = $9 \times 10^6 \text{ J}$ 。
省略.....

参考输出（正确使用物理公式）

.....省略.....
 1. 计算燃料释放的总热量：[总热量] = [燃料质量] $\times$ [热值] = $0.3 \times 4 \times 10^7 = 1.2 \times 10^7 \text{ J}$ 。
 2. 计算雪地清扫机所做的功：[总功] = [总热量] - [释放的热量] = $1.2 \times 10^7 \text{ J} - 9 \times 10^6 \text{ J} = 3 \times 10^6 \text{ J}$ 。
省略.....

图 4-1 模型错误使用公式导致问题解答错误

在错误分析上，本文给出两个具体的示例。公式使用错误是其中主要的错误类型，如图4-1所示，在计算步骤中错误的公式应用导致了错误的结果。解答过程中还有因参数扰动注入（见3.3节）而产生的错误，如图4-2所示，模型使用注入的参数进行计算，导致了错误结果。在模型的表现方面，本文发现，问题中注入的参数扰动对准确度较高的模型影响较小。例如，在 DeepSeek-R1 未能提供正确答案的问题中，大约 14% 受到了参数噪声的影响。这表明，本文的问题变换步骤对模型正确应用公式和进行准确推理的能力提出了更高的要求。




图 4-2 模型使用注入的参数扰动导致问题解答错误

4.3 检索增强生成方法评测

4.3.1 实现细节

对于检索器中的文本编码器，本文使用了 BERT 模型的变种 BERT-wwm-ext^[63]。在中文的语义理解上，该模型较于 BERT 模型有更好的效果。

检索器训练时计算文本与公式相似度时的温度参数 τ 设置为 1，学习率设置为 $1\text{e-}4$ ，训练轮次设置为 10，训练批次大小设置为 8，梯度累计设置为 8。

对于生成阶段，本文评测了 DeepSeek-R1 和 ERNIE-4.5-21B-A3B 模型，分别代表能力较为突出和能力较为一般的大语言模型。本实验中取检索结果的前 3 或前 5 个公式来辅助生成，含公式的提示词如附录A-9所示。

4.3.2 评测结果

该方法在 HeF 测试集上进行实验的意义较小，因为在训练检索器时，所需的公式可能并未包含在其中，以下主要为 HoF 测试集的实验结果。

按照上文所述训练的检索器结果如表4-5所示，在前 5 个检索结果中已经能够覆盖大部分需要的公式；继续提高检索结果数量能带来的召回率提高十分有限，将检索结果数量提升至 20 也只能提高约 3.4% 的召回率。

另外由表2-1可知，本文数据集的平均推理步骤不足 5 步，因此前 5 条检索

表 4-5 检索器的结果 (@n 表示取检索的前 n 个结果)

RAG@n	召回率	准确率
RAG@1	39.02	85.68
RAG@3	74.42	65.33
RAG@5	82.46	45.08
RAG@20	85.84	11.92

结果很可能包含较多的无关公式，本文中检索器的召回率能够达到较高水平，但是准确率仍需提高。另外，由于不同问题所需的公式数量不同，固定检索结果数量的灵活性也较低。这都表明对公式的精细化检索也是未来需要进行探索的方向。

表 4-6 检索增强生成的准确率结果 (@n 表示取检索的前 n 个结果用于生成)

RAG@n	ERNIE-4.5-21B-A3B	DeepSeek-R1
RAG@0	66.34	88.62
RAG@3	70.22	94.92
RAG@5	69.73	91.04

本文选取了 DeepSeek-R1 和 ERNIE-4.5-21B-A3B 进行检索增强生成的实验，在表4-6中展示了相应的实验结果。其中 RAG@0 代表不使用检索结果，即零样本实验的结果，RAG@3 和 RAG@5 分别代表取前 3 个检索结果和取前 5 个检索结果进行实验。

表中结果表明，将检索到的公式融入提示词中可以提高大语言模型的性能。RAG@3 的准确率比 RAG@5 的准确率高，这说明在检索结果增多后，其中无关的公式影响了模型的生成结果，尽管如此，检索结果仍然对模型生成结果呈正向影响。

4.4 模型微调方法评测

4.4.1 实现细节

在此实验中模型选择了 Qwen2.5-Math-1.5B-Instruct^[53]和 Qwen2.5-Math-7B-Instruct^[53]两个参数量具有代表性的模型。

本文在 NVIDIA RTX 3090 (24G) 进行监督微调的实验：对于 1.5B 模型选

用全量微调，训练时的学习率设置为 $1e-4$ ，训练轮次设置为 3，训练批次大小设置为 1，梯度累计设置为 8，预热比率设置为 0.1；对于 7B 模型选用 LoRA 微调，LoRA 矩阵的秩设置为 8，其余参数均与全量微调时参数一致。与大语言模型普遍的微调方式一致，本文也采用交叉熵损失函数进行训练。

利用数据增广得到的新数据混入原始训练集并不总是带来正向的改善，可能是因为新生成的数据没有经过人工审核。实验过程中将混合数据中增广数据的比例设置为原数据的 10%（这是一个经实验得到的经验比例）。数据增广方法的微调参数设置和未进行数据增广的参数设置完全一致。

4.4.2 评测结果

表 4-7 监督微调模型的准确率结果

模型	HoF	HeF	均值
Qwen2.5-Math-7B-Instruct			
+ 普通微调	65.62	58.91	62.27
+ 数据增广	67.55	62.53	65.04
Qwen2.5-Math-1.5B-Instruct			
+ 普通微调	64.41	55.56	59.99
+ 数据增广	66.59	59.17	62.88

表4-7展示了经过监督微调的模型的结果，评测了使用训练集进行普通微调的方法和额外使用增广数据进行监督微调的方法的准确率。

实验结果表明，增广数据使得模型在公式数据集上的效果得到提高。在大多数设置下，两个模型在 HoF 测试集上的得分均高于 HeF 测试集，但它们在后者上的表现仍然相当不错。这表明，未见过的公式影响了模型的表现，尽管如此，它们仍表现出一定的泛化能力。

4.5 直接偏好优化方法评测

4.5.1 实现细节

直接偏好优化实验中选择的模型包括不同大小以及在不同数据方向进行训练的模型，包括进行指令微调的 Qwen2.5-1.5B-Instruct^[53]，在数学领域进行训练的 Qwen2.5-Math-1.5B-Instruct^[53]，利用 Deepseek-R1 进行知识蒸馏的模型

DeepSeek-R1-Distill-Qwen-1.5B^[51],更大参数量的模型 DeepSeek-R1-Distill-Qwen-7B^[51]。

本文在 NVIDIA RTX 3090 (24G) 进行直接偏好优化的训练：敏感度参数 β 设置为 0.1，学习率设置为 $5e-7$ ，训练轮次设置为 30，训练批次大小设置为 1，梯度累计设置为 4，预热比率设置为 0.05。

4.5.2 评测结果

表 4-8 直接偏好优化方法在各个数据集的准确率结果

模型	GSM8K	MATH	SVAMP	Gaokao2023-en	FormulaReasoning
DeepSeek-R1-Distill-Qwen-7B	87.7	58.8	87.7	55.3	34.0
+ 直接偏好优化	85.8 -1.9	59.7 +0.9	88.1 +0.4	55.8 +0.5	37.0 +3.0
DeepSeek-R1-Distill-Qwen-1.5B	79.8	68.2	85.7	55.3	7.23
+ 直接偏好优化	81.3 +1.5	68.0 -0.2	86.3 +0.6	55.1 -0.2	10.47 +3.24
Qwen2.5-Math-1.5B-Instruct	85.6	76.1	93.3	66.0	4.94
+ 直接偏好优化	85.8 +0.2	76.5 +0.4	93.7 +0.4	65.2 -0.8	7.52 +2.58
Qwen2.5-1.5B-Instruct	72.9	55.0	85.5	47.5	5.94
+ 直接偏好优化	73.1 +0.2	56.2 +1.2	86.6 +1.1	47.8 +0.3	6.57 +0.63

该实验利用从 FormulaReasoning 的训练集得到的偏好数据，通过直接偏好优化方法在多个小型模型上进行实验，不仅在 FormulaReasoning 的测试集上，也在其他数值推理数据集上进行了测试。

表4-8展示了实验结果，直接偏好优化方法不仅提高了模型在 FormulaReasoning 上的准确率，在大多数其他数据集上也提高了准确率，表明从本文提出的数据集中获得的偏好数据具有额外的价值。值得注意的是，尽管这些模型在其他数据集上表现良好，但它们在 FormulaReasoning 上的低准确率表明，它们并未真正掌握物理领域中所需的基于公式的推理，这使得 FormulaReasoning 成为一个有价值的数据集，为大语言模型提供了独特的挑战。

4.6 本章总结

本章对 FormulaReasoning 进行了基本的方法评测。评测以零样本方法为主，展示了包括检索增强生成、模型微调、直接偏好优化等多种与大语言模型相关的方法评测。本章对各个方法的原理、设置、结果均给出了说明与分析。下一章将介绍本文提出的一种基于公式的数值推理方法。

第五章 一种基于公式的数值推理方法

本章介绍了一种基于公式的数值推理方法。在5.1节中阐述了方法的核心思想与概况，在5.2节中对该方法的具体实现进行了详细描述，在5.3节中介绍了评测的基本设置，在5.4节中展示了各个实验及结果。

5.1 方法概述

在目前的数值推理方法中，许多大语言模型相关的数值推理方法缺少公式知识的指导，并且由单一模型负责全部的解题流程，不仅包括文本理解、还包括公式思路的推理和数值计算。这些方法由于没有公式知识的显式指导，容易出现幻觉，缺乏知识的可解释性，而且对单一模型的要求较高。在基于公式的推理数据集上，即使是参数量较大的模型也会出现推理步骤不清晰、计算准确性较低等问题，对于参数量较小的模型来说则更具挑战。

针对以上问题，本文提出一种基于公式的数值推理方法。该方法基于公式将数值推理任务拆分为多个子任务，让不同的模型解决不同的任务。在这个方法中，将解决数值推理问题的过程分为三个步骤：公式生成、参数识别和数值计算。公式生成和参数识别两个步骤由两个不同的模型分别负责：负责公式生成任务的模型仅关注问题的推理过程并给出相应公式，不参与任何计算方面的内容考虑，而负责参数识别任务的模型仅关注公式中各个参数内容是什么，不考虑问题的推理过程如何进行。数值计算部分，该方法则使用外部计算器而非神经网络为基础的模型，以此来保证整体计算的准确可靠。

在公式生成步骤，由于使用了显式的知识描述，使得模型更不容易出现幻觉情况，也使得步骤在知识层面的可解释性得到提高；另外，这种分工协作的方法能够让模型分别专注于较简单的子任务，而不必负责全部的数值推理内容，分开处理公式推理与计算的思路有效提升了数值推理的准确性，尤其在处理复杂任务和多步骤推理时，能够显著减少错误和计算不一致的情况出现；同时，这种方

法也给模型的改进优化提供了更宽松的空间，每个子任务的模型可以分别进行优化而不影响其他模块的表现。

使用这种方法，模型在基于公式的数值推理数据集上能够实现更加高效、精准的数值推理，为实际应用中的各种问题提供更加优质的解决方案。

5.2 方法实现

本方法需要对模型进行训练，所以下面从训练数据构建以及方法流程两方面进行方法实现的介绍。

5.2.1 基于公式的训练数据构建

由于现有的数值推理数据集中很少涉及公式推理的直接描述，该方法中各个子任务的模型均需要构建相应训练数据并对模型进行监督微调以适应该任务。

公式生成 对大语言模型进行监督微调的训练数据可简化至输入和输出（即标签）。公式生成任务对应的训练数据中，输入即为由数据集中的数值推理问题参与构成的提示词，输出则为解决该数值推理所需的一系列公式。输出的公式顺序与解题时的推理顺序一致，每一个公式都由参数名和可操作的运算符构成，为更清晰地区分参数名和运算符，公式中各个参数均放置在“[]”符号内。例如公式“[质量]=[密度]*[体积]”中，“*”表示乘法运算，“=”表示等价关系，“[密度]”则表示公式中参数名为“密度”的参数。详细的输入输出模板见附录A-10，使用该数据进行监督微调得到的大语言模型在公式生成模块中使用。

参数识别 参数识别任务对应的训练数据中，输入除了数据集中的数值推理问题之外，还包括公式中的参数名称，输出则为参数对应的具体数值和单位，若参数无单位（例如为系数或比率）则输出中单位为空。该训练数据强调对题目进行数据上的检索，而非计算推理，所以训练数据中涉及的参数均是可以直接通过题目得到的，而不是需要经过计算得出的。详细的输入输出模板见附录A-11，使用该数据进行监督微调得到的大语言模型在参数识别模块中使用。

5.2.2 基于公式的数值推理方法

该方法的输入为数值推理问题，是字符串形式的文本，输出为数值推理问题的答案，是由数值和单位组成的参数。下面从三个模块分别详细阐述。

公式生成 该模块输入为数值推理问题，输出为公式。通过将数值推理问题嵌入提示词模板中的问题位置，得到公式提示词文本。将公式提示词文本传入大语言模型进行推理，并根据预先设置的词元进行生成文本的识别，当生成完整的公式之后停止生成。将数值推理问题和公式传入参数识别模块。

参数识别 该模块输入为数值推理问题和公式，输出为参数（包括名称、数值和单位）。首先使用正则方法，提取公式中的计算目标和计算表达式（即公式中等号左侧和右侧内容），通过检测计算表达式中的参数标识，得到表达式中的所有参数名称。由于计算目标属于待计算参数，该参数不能通过题目直接获取，故不需要对其进行参数识别。对于每一个计算表达式中的参数，将数值推理问题和参数名称嵌入提示词模板中的问题和参数位置，得到参数提示词文本。将参数提示词文本传入大语言模型进行推理，得到各个参数对应的数值和单位，即完整的参数。最后将公式和已知的各个参数传入数值计算模块。

数值计算 该模块输入为公式和参数，输出为当前计算结果。该模块对于每个题目均有一个结果表，初始化为空，用于记录当前得到的各个计算结果，包括参数的名称，对应的计算数值等。当接收输入后，该模块首先使用正则方法，得到计算表达式中的各个参数名称。如果计算表达式中的参数在结果表中有对应的结果记录，那么将对应的数值和单位带入计算表达式，如果没有对应记录，则将输入中参数对应的数值和单位带入计算表达式。将参数结果全部带入计算表达式之后，使用 Numbat 进行带单位的计算。由此得到了计算目标的结果，并将其记录在结果表中。

该方法总体的流程图如图5-1所示。问题经过公式生成模块，该模块将问题输入大语言模型，由大语言模型给出相应的公式内容；经过基于正则表达式的提取方法，将公式中的参数进行提取，与问题共同构成参数识别模块的输入，经过该模块之后得到各个参数的具体数值和单位；将公式和参数传入数值计算模块，




图 5-1 基于公式的数值推理方法流程图

使用外部计算器 Numbat 进行计算，并记录结果。按照上述步骤完成一轮公式计算后重复此过程，直至公式生成模块没有新的公式并且所有公式都计算完成，至此完成数值推理问题的完整解答过程。

5.3 评测设置

5.3.1 基线方法

本文除了对上述方法进行评测之外，还与其他监督微调的方法进行了对比。与4.4节中的方法一致，本文将普通微调方法和数据增广方法作为本章方法的基线对比方法。

由于较大参数量的模型需要耗费过多的资源，在本文中需要微调的实验主要在 8B 及以下参数大小的模型上进行，在本节的实验中，使用 Qwen2.5-Math-1.5B-Instruct^[53]和 Qwen2.5-Math-7B-Instruct^[53]来作为两个有代表性的模型进行实验，具体的训练参数与4.4节保持一致。本章没有选用其他方法（例如零样本测评或直接偏好优化等方法）和本章提出的方法进行对比，是因为在这些方法中，8B 及以下参数量的模型表现效果较差，较难具备参考意义。

5.3.2 数据集

正如表2-1所示，本数据集中 100% 的题目均需要公式进行计算，相较于其他数据集更适合评估基于公式的数值推理方法。本章实验中所使用的数据集为 FormulaReasoning 和其增强版数据集 FormulaReasoning+。

5.3.3 评测指标

本章所使用的评测指标为准确率。该计算方式与4.1.3节中所述一致，使用基于正则的方法进行答案提取，然后利用计算器对比模型答案和参考答案得出准确率。

5.4 评测结果

5.4.1 对比实验

表 5-1 各方法下模型在 FormulaReasoning 上的准确率结果

模型	HoF	HeF	均值
Qwen2.5-Math-7B-Instruct			
+ 普通微调	65.62	58.91	62.27
+ 数据增广	67.55	62.53	65.04
+ 本文方法	74.09	65.63	69.86
Qwen2.5-Math-1.5B-Instruct			
+ 普通微调	64.41	55.56	59.99
+ 数据增广	66.59	59.17	62.88
+ 本文方法	67.80	58.66	63.23

表5-1展示了本文方法和其他方法的实验结果。在总体表现上，Qwen2.5-Math-7B-Instruct 的表现相较于 Qwen2.5-Math-1.5B-Instruct 更强。7B 模型由于参数量相对较大，其训练使用的是 LoRA 微调方式，该方式仅能微调低秩矩阵，在具体任务上的效果并不如全量微调，即使如此，其在 HoF 和 HeF 测试集上分别达到了 65.62、58.91 的准确率，相比于全量微调的 1.5B 模型（在 HoF 和 HeF 上的准确率分别为 64.41、55.56）有着更高的准确率。在数据增广和本章提出的方法中，7B 的模型也比 1.5B 模型有着更好的效果，7B 模型在两种方法上平均准确率为 65.04 和 69.86，明显高于 1.5B 模型的 62.88 和 63.23。这说明了更大参数量的模型对于基于公式的任务能够有更好的表现，这也验证了尺度定律。

在与其他方法的对比中，本章中提出的方法有着明显的优势。本文方法相比数据增广显示出更为显著的效果提升，尤其是在 Qwen2.5-Math-7B-Instruct 中，本文方法的增益（7.59）明显高于数据增广方法的增益（2.77），对于 Qwen2.5-Math-1.5B-Instruct 而言，虽然本文方法和数据增广方法的性能差距没有像 7B 模型那么明显，但本文方法仍然优于数据增广方法带来的性能提升（分别为 3.24 和 2.89）。

表 5-2 各方法下模型在 FormulaReasoning+ 上的准确率结果

模型	HoF	HeF	均值
Qwen2.5-Math-7B-Instruct			
+ 普通微调	22.17	22.49	22.33
+ 数据增广	23.15	24.87	24.01
+ 本文方法	43.35	45.77	44.56
Qwen2.5-Math-1.5B-Instruct			
+ 普通微调	27.09	29.63	28.36
+ 数据增广	30.05	33.07	31.56
+ 本文方法	34.98	31.75	33.37

除了 FormulaReasoning 上进行实验外，本文还在 FormulaReasoning+ 上进行了对应的实验，结果如表5-2所示。

FormulaReasoning+ 的难度使得模型的准确率大幅下降：在没有其他方法增强的微调策略下，Qwen2.5-Math-7B-Instruct 从 62.27 下降至了 22.33，而 Qwen2.5-Math-1.5B-Instruct 从 59.99 下降至了 28.36；在其他方法下模型效果也有较为明显的下降，例如 7B 模型在本文方法下从 69.86 下降至 44.56，1.5B 模型在数据增广方法下从 62.88 下降至 31.56。这样大幅度的准确率下降也反映出 FormulaReasoning+ 相较于 FormulaReasoning 难度有了明显的提升，本文设计的难度增强方案给当前模型带来了较大的挑战。

与 FormulaReasoning 上的实验结果类似，在增强版数据集上，本文提出的方法相比于普通微调方法或者数据增强方法效果都有提高。但值得关注的一点是，在 FormulaReasoning+ 的普通微调方法和数据增广方法上，Qwen2.5-Math-7B-Instruct 所达到的准确率比 Qwen2.5-Math-1.5B-Instruct 更低，而在本文方法中 7B 模型的效果比 1.5B 更好。这是由于 7B 对应模型使用了 LoRA 微调，而 1.5B 模型使用的是全量微调。随着题目难度的增加，LoRA 微调这类微调方式已经难以满足复杂的任务需求，其低秩矩阵所提供的模型优化空间不足以兼顾复杂的

公式推理和数值计算；而本文方法中，模型可以更专注于公式推理，7B 的模型相较于 1.5B 模型的推理优势得到体现。

5.4.2 消融实验

本文对该方法还进行了消融实验，验证将复杂问题拆解成多模型子任务的有效性。

表 5-3 多模型和单模型设置的消融实验

模型	FormulaReasoning			FormulaReasoning+		
	HoF	HeF	均值	HoF	HeF	均值
Qwen2.5-Math-7B-Instruct	65.62	58.91	62.27	22.17	22.49	22.33
+ 单模型	72.64 +7.02	65.63 +6.72	69.14 +6.87	44.83 +22.66	43.12 +20.63	43.98 +21.65
+ 多模型	74.09 +8.47	65.63 +6.72	69.86 +7.59	43.35 +21.18	45.77 +23.28	44.56 +22.23
Qwen2.5-Math-1.5B-Instruct	64.41	55.56	59.99	27.09	29.63	28.36
+ 单模型	66.34 +1.93	53.75 -1.81	60.05 +0.06	32.02 +4.93	29.63 +0.00	30.83 +2.47
+ 多模型	67.80 +3.39	58.66 +3.10	63.23 +3.24	34.98 +7.89	31.75 +2.12	33.37 +5.01

在表5-3中，单模型代表仅用一个模型完成公式推理和参数提取，该模型由5.2.1节中提到的所有数据进行训练，多模型则代表本文提出的方法中对应的设置，实验中两种设置的模型训练参数一致。

以 Qwen2.5-Math-1.5B-Instruct 为例，相较于单一模型设置，本文方法在 FormulaReasoning 上提高了 3.18，在 FormulaReasoning+ 上提高了 2.54。实验结果表明，不论是在 FormulaReasoning 还是难度增强后的 FormulaReasoning+ 数据集上，多模型协作的方式都较单一模型的效果有所提升。这也验证了该方法的有效性：将问题拆解为各个子任务，不同模型负责不同的任务降低了对模型的要求，使得整体解题性能得到提高。

5.4.3 多公式候选实验

本文所提出的方法能够使模型专注于公式推理，本文还进行了实验来探索模型在多条公式推理路径中的能力。

表5-4中，@1 表示 1 次尝试，与前文实验中的设置一致；@3 表示最多 3 次尝试，这让模型最多给出三条完整的公式推理路径，如果这 3 次尝试中任意一次回答正确，则视为模型回答正确。

表 5-4 不同候选公式路径数量下模型的准确率结果

模型	FormulaReasoning			FormulaReasoning+		
	HoF	HeF	均值	HoF	HeF	均值
Qwen2.5-Math-7B-Instruct	65.62	58.91	62.27	22.17	22.49	22.33
+ 本文方法 @1	74.09 +8.47	65.63 +6.72	69.86 +7.59	43.35 +21.18	45.77 +23.28	44.56 +22.23
+ 本文方法 @3	79.66 +14.02	76.74 +17.83	78.20 +15.97	50.74 +28.57	52.65 +30.16	51.70 +29.37
Qwen2.5-Math-1.5B-Instruct	64.41	55.56	59.99	27.09	29.63	28.36
+ 本文方法 @1	67.80 +3.39	58.66 +3.10	63.23 +3.24	34.98 +7.89	31.75 +2.12	33.37 +5.01
+ 本文方法 @3	74.82 +10.41	64.34 +8.78	69.58 +9.59	41.13 +14.04	39.95 +10.32	40.54 +12.18

以 Qwen2.5-Math-1.5B-Instruct 为例，在多次公式推理路径的尝试后，模型答案的准确率由 63.23 提升至 69.58，在难度增强后的数据集上也有 7.17 的准确率提升。表中的实验结果表明，在允许多条推理路径尝试时，模型的准确率有了更多的提高，这也反映出模型在公式推理上仍有较大的学习空间。

5.5 本章总结

本章介绍了一种基于公式的数值推理方法。该方法将复杂的公式推理任务拆分成为公式生成、参数识别、数值计算三个子任务，通过公式知识的显式指导、专注于不同子任务的多模块设计以及计算器的辅助达到数值推理效果上的提升。本章除了对方法进行了详细说明，还进行了多个实验。在与其他方法的对比中，本文提出的方法优于其他基线方法；在消融实验中验证了本文方法中多模型结构的有效性；在多公式候选实验中探究了多公式路径的性能表现。下一章将对本文的工作进行总结，并对未来研究进行展望探讨。

第六章 结论与展望

本章在6.1节对本文的研究内容做出了较为全面的总结，在6.2节中基于现有工作，对未来的研究做出讨论与展望。

6.1 研究总结

数值推理中目前仍然缺乏对公式这类显式知识的研究，基于公式的推理研究对提升当前大语言模型的数值推理能力具有重要意义。本文针对公式构建了一个数值推理数据集，并在该数据集上进行了众多方法的评测和方法探究。

本文首先提出了 FormulaReasoning 数据集以及其增强版本 FormulaReasoning+ 数据集，详细阐述了其构建过程。首先进行题目收集和预处理，接着在大语言模型辅助下进行了公式标注，提供细粒度知识内容，最后通过问题变换方案和难度增强方案分别构建出 FormulaReasoning 和 FormulaReasoning+ 数据集，并进行了翻译工作使其成为中英文双语数据集。本文基于数据集还提供了一些其他的数据资源，包括和数据集内容对应的公式库、增广数据、直接偏好优化数据等。

对于提出的数据集，本文进行了众多模型以及多种方法的评测，模型参数大小涉及 1.5B 至 200B 以上，包括零样本、检索增强生成、监督微调、直接偏好优化等方法，给出了较为详细的实验结果和分析。

本文还提出一种基于公式的数值推理方法来提升模型的性能。该方法将数值推理分为三个子任务模块来构建解题流程，分别是公式生成、参数识别、数值计算。在公式生成和参数识别中，分别由一个大语言模型进行相应具体任务的推理，在数值计算中，使用计算器来进行准确的运算。在与其他监督微调相关方法的对比中，本文提出的方法优于其他基线方法；在消融实验中，验证了本文子任务模块的有效性；在多公式候选实验中，本文提供了不同公式路径数量的模型表现。

6.2 未来展望

本文在基于公式的数值推理领域上进行了数据集的构建，进行了多样的测评，并提出了一种基于公式的数值推理方法。但本文仍然有着一定的局限性和不足之处，也为未来的研究工作提供了参考和建议：

1. 本文所进行的检索增强方法实验中，使用的公式库是基于本文提出的数据集构建的。这意味着模型面对其他领域的数据内容时，难以提供正确的公式，对于公式的构建与检索仍需要进一步研究，使得公式能够不局限于数据集和领域要求。

2. 本文的数据集是基于初高中物理题目构建的，这一题目来源的难度相对较低，且领域范围有限。未来对于公式数据集的构建应当涉及更多领域（例如金融领域、化学领域等），并且进一步考虑问题难度的增强。

3. 本文对公式在模型推理中的过程监督研究不足。由于公式形式多样且解题路径并不单一，本文仅通过过程打分模型来对过程进行粗粒度的评价，而没有利用公式进行过程评价与监督。未来应该考虑更多的过程评价指标以及如何用公式对模型微调过程进行数据监督与性能提高。

参考文献

- [1] BROWN T B, MANN B, RYDER N, et al. Language Models are Few-Shot Learners[C/OL]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual. 2020. <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>.
- [2] OpenAI. GPT-4 Technical Report[J/OL]. CoRR, 2023, abs/2303.08774. arXiv: 2303.08774. <https://doi.org/10.48550/arXiv.2303.08774>. DOI: 10.48550/ARXIV.2303.08774.
- [3] BAI J, BAI S, CHU Y, et al. Qwen Technical Report[J/OL]. CoRR, 2023, abs/2309.16609. arXiv: 2309.16609. <https://doi.org/10.48550/arXiv.2309.16609>. DOI: 10.48550/ARXIV.2309.16609.
- [4] YANG A, YANG B, HUI B, et al. Qwen2 Technical Report[J/OL]. CoRR, 2024, abs/2407.10671. arXiv: 2407.10671. <https://doi.org/10.48550/arXiv.2407.10671>. DOI: 10.48550/ARXIV.2407.10671.
- [5] ZENG A, XU B, WANG B, et al. ChatGLM: A Family of Large Language Models from GLM-130B to GLM-4 All Tools[J/OL]. CoRR, 2024, abs/2406.12793. arXiv: 2406.12793. <https://doi.org/10.48550/arXiv.2406.12793>. DOI: 10.48550/ARXIV.2406.12793.
- [6] COBBE K, KOSARAJU V, BAVARIAN M, et al. Training Verifiers to Solve Math Word Problems[J/OL]. CoRR, 2021, abs/2110.14168. arXiv: 2110.14168. <https://arxiv.org/abs/2110.14168>.

- [7] FRIEDER S, PINCHETTI L, CHEVALIER A, et al. Mathematical Capabilities of ChatGPT[C/OL]//OH A, NAUMANN T, GLOBERSON A, et al. Advances in Neural Information Processing Systems 36: Annual Conference on Neural Information Processing Systems 2023, NeurIPS 2023, New Orleans, LA, USA, December 10 - 16, 2023. 2023. http://papers.nips.cc/paper%5C_files/paper/2023/hash/58168e8a92994655d6da3939e7cc0918-Abstract-Datasets%5C_and%5C_Benchmarks.html.
- [8] LIU J, HUANG Z, MA Z, et al. Guiding Mathematical Reasoning via Mastering Commonsense Formula Knowledge[C/OL]//SINGH A K, SUN Y, AKOGLU L, et al. Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, KDD 2023, Long Beach, CA, USA, August 6-10, 2023. ACM, 2023: 1477-1488. <https://doi.org/10.1145/3580305.3599375>. DOI: 10.1145/3580305.3599375.
- [9] SCHUSTER M, NAKAJIMA K. Japanese and Korean voice search[C/OL]//2012 IEEE International Conference on Acoustics, Speech and Signal Processing, ICASSP 2012, Kyoto, Japan, March 25-30, 2012. IEEE, 2012: 5149-5152. <https://doi.org/10.1109/ICASSP.2012.6289079>. DOI: 10.1109/ICASSP.2012.6289079.
- [10] KUDO T, RICHARDSON J. SentencePiece: A simple and language independent subword tokenizer and detokenizer for Neural Text Processing[C/OL]//BLANCO E, LU W. Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, EMNLP 2018: System Demonstrations, Brussels, Belgium, October 31 - November 4, 2018. Association for Computational Linguistics, 2018: 66-71. <https://doi.org/10.18653/v1/d18-2012>. DOI: 10.18653/V1/D18-2012.
- [11] MIKOLOV T, CHEN K, CORRADO G, et al. Efficient Estimation of Word Representations in Vector Space[C/OL]//BENGIO Y, LECUN Y. 1st International Conference on Learning Representations, ICLR 2013, Scottsdale, Arizona, USA,

- May 2-4, 2013, Workshop Track Proceedings. 2013. <http://arxiv.org/abs/1301.3781>.
- [12] PENNINGTON J, SOCHER R, MANNING C D. Glove: Global Vectors for Word Representation[C/OL]// MOSCHITTI A, PANG B, DAELEMANS W. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, EMNLP 2014, October 25-29, 2014, Doha, Qatar, A meeting of SIG-DAT, a Special Interest Group of the ACL. ACL, 2014: 1532-1543. <https://doi.org/10.3115/v1/d14-1162>. DOI: 10.3115/V1/D14-1162.
- [13] PETERS M E, NEUMANN M, IYYER M, et al. Deep Contextualized Word Representations[C/OL]// WALKER M A, JI H, STENT A. Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2018, New Orleans, Louisiana, USA, June 1-6, 2018, Volume 1 (Long Papers). Association for Computational Linguistics, 2018: 2227-2237. <https://doi.org/10.18653/v1/n18-1202>. DOI: 10.18653/V1/N18-1202.
- [14] DEVLIN J, CHANG M, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C/OL]// BURSTEIN J, DORAN C, SOLORIO T. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019, Minneapolis, MN, USA, June 2-7, 2019, Volume 1 (Long and Short Papers). Association for Computational Linguistics, 2019: 4171-4186. <https://doi.org/10.18653/v1/n19-1423>. DOI: 10.18653/V1/N19-1423.
- [15] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is All you Need[C/OL]// GUYON I, von LUXBURG U, BENGIO S, et al. Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA. 2017: 5998-6008. <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>.

- [16] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling Laws for Neural Language Models[J/OL]. CoRR, 2020, abs/2001.08361. arXiv: 2001.08361. <https://arxiv.org/abs/2001.08361>.
- [17] KONG Y, YANG Y, HWANG Y, et al. Time-MQA: Time Series Multi-Task Question Answering with Context Enhancement[C/OL]//CHE W, NABENDE J, SHUTOVA E, et al. Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2025, Vienna, Austria, July 27 - August 1, 2025. Association for Computational Linguistics, 2025: 29736-29753. <https://aclanthology.org/2025.acl-long.1437/>.
- [18] HENDRYCKS D, BURNS C, KADAVATH S, et al. Measuring Mathematical Problem Solving With the MATH Dataset[C/OL]//VANSCHOREN J, YE-UNG S. Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks 1, NeurIPS Datasets and Benchmarks 2021, December 2021, virtual. 2021. <https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/hash/be83ab3ecd0db773eb2dc1b0a17836a1-Abstract-round2.html>.
- [19] KONCEL-KEDZIORSKI R, ROY S, AMINI A, et al. MAWPS: A Math Word Problem Repository[C/OL]//KNIGHT K, NENKOVA A, RAMBOW O. NAACL HLT 2016, The 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, San Diego California, USA, June 12-17, 2016. The Association for Computational Linguistics, 2016: 1152-1157. <https://doi.org/10.18653/v1/n16-1136>. DOI: 10.18653/V1/N16-1136.
- [20] WANG Y, LIU X, SHI S. Deep Neural Solver for Math Word Problems[C/OL]//PALMER M, HWA R, RIEDEL S. Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, EMNLP 2017, Copenhagen, Denmark, September 9-11, 2017. Association for Computational Linguistics, 2017: 845-854. <https://doi.org/10.18653/v1/d17-1088>. DOI: 10.18653/V1/D17-1088.

- [21] AMINI A, GABRIEL S, LIN S, et al. MathQA: Towards Interpretable Math Word Problem Solving with Operation-Based Formalisms[C/OL]// BURSTEIN J, DORAN C, SOLORIO T. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019, Minneapolis, MN, USA, June 2-7, 2019, Volume 1 (Long and Short Papers). Association for Computational Linguistics, 2019: 2357-2367. <https://doi.org/10.18653/v1/n19-1245>. DOI: 10.18653/V1/N19-1245.
- [22] HUANG Z, SHEN Y, LI X, et al. GeoSQA: A Benchmark for Scenario-based Question Answering in the Geography Domain at High School Level[C/OL]// INUI K, JIANG J, NG V, et al. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, EMNLP-IJCNLP 2019, Hong Kong, China, November 3-7, 2019. Association for Computational Linguistics, 2019: 5865-5870. <https://doi.org/10.18653/v1/D19-1597>. DOI: 10.18653/V1/D19-1597.
- [23] SHEN J, YUAN Y, MIRZOYAN S, et al. Measuring Vision-Language STEM Skills of Neural Models[C/OL]//The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024. OpenReview.net, 2024. <https://openreview.net/forum?id=spvaV5LELF>.
- [24] LU P, MISHRA S, XIA T, et al. Learn to Explain: Multimodal Reasoning via Thought Chains for Science Question Answering[C/OL]//KOYEJO S, MOHAMED S, AGARWAL A, et al. Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022. 2022. http://papers.nips.cc/paper%5C_files/paper/2022/hash/11332b6b6cf4485b84afadb1352d3a9a-Abstract-Conference.html.
- [25] DUA D, WANG Y, DASIGI P, et al. DROP: A Reading Comprehension Benchmark Requiring Discrete Reasoning Over Paragraphs[C/OL]//BURSTEIN J,

- DORAN C, SOLORIO T. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019, Minneapolis, MN, USA, June 2-7, 2019, Volume 1 (Long and Short Papers). Association for Computational Linguistics, 2019: 2368-2378. <https://doi.org/10.18653/v1/n19-1246>. DOI: 10.18653/V1/N19-1246.
- [26] YU L, JIANG W, SHI H, et al. MetaMath: Bootstrap Your Own Mathematical Questions for Large Language Models[C/OL]//The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024. OpenReview.net, 2024. <https://openreview.net/forum?id=N8N0hgND Rt>.
- [27] TOSHNIWAL S, DU W, MOSHKOV I, et al. OpenMathInstruct-2: Accelerating AI for Math with Massive Open-Source Instruction Data[C/OL]//The Thirteenth International Conference on Learning Representations, ICLR 2025, Singapore, April 24-28, 2025. OpenReview.net, 2025. <https://openreview.net/forum?id=mTCbq2QssD>.
- [28] HOSSEINI M J, HAJISHIRZI H, ETZIONI O, et al. Learning to Solve Arithmetic Word Problems with Verb Categorization[C/OL]//MOSCHITTI A, PANG B, DAELEMANS W. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, EMNLP 2014, October 25-29, 2014, Doha, Qatar, A meeting of SIGDAT, a Special Interest Group of the ACL. ACL, 2014: 523-533. <https://doi.org/10.3115/v1/d14-1058>. DOI: 10.3115/V1/D14-1058.
- [29] KUSHMAN N, ZETTLEMOYER L, BARZILAY R, et al. Learning to Automatically Solve Algebra Word Problems[C/OL]//Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics, ACL 2014, June 22-27, 2014, Baltimore, MD, USA, Volume 1: Long Papers. The Association for Computer Linguistics, 2014: 271-281. <https://doi.org/10.3115/v1/p14-1026>. DOI: 10.3115/V1/P14-1026.

- [30] SHI S, WANG Y, LIN C, et al. Automatically Solving Number Word Problems by Semantic Parsing and Reasoning[C/OL]//MÀRQUEZ L, CALLISON-BURCH C, SU J, et al. Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, EMNLP 2015, Lisbon, Portugal, September 17-21, 2015. The Association for Computational Linguistics, 2015: 1132-1142. <https://doi.org/10.18653/v1/d15-1135>. DOI: 10.18653/V1/D15-1135.
- [31] KIM J, KANG J, KIM K, et al. Exploiting Numerical-Contextual Knowledge to Improve Numerical Reasoning in Question Answering[C/OL]//CARPUAT M, de MARNEFFE M, RUÍZ I V M. Findings of ACL: Findings of the Association for Computational Linguistics: NAACL 2022, Seattle, WA, United States, July 10-15, 2022: vol. NAACL 2022. Association for Computational Linguistics, 2022: 1811-1821. <https://doi.org/10.18653/v1/2022.findings-naacl.138>. DOI: 10.18653/V1/2022.FINDINGS-NAACL.138.
- [32] GUPTA N, LIN K, ROTH D, et al. Neural Module Networks for Reasoning over Text[C/OL]//8th International Conference on Learning Representations, ICLR 2020, Addis Ababa, Ethiopia, April 26-30, 2020. OpenReview.net, 2020. <https://openreview.net/forum?id=SygWvAVFPr>.
- [33] CHEN J, GUO X, LI Y, et al. Teaching Neural Module Networks to Do Arithmetic[C/OL]//CALZOLARI N, HUANG C, KIM H, et al. Proceedings of the 29th International Conference on Computational Linguistics, COLING 2022, Gyeongju, Republic of Korea, October 12-17, 2022. International Committee on Computational Linguistics, 2022: 1502-1510. <https://aclanthology.org/2022.coling-1.129>.
- [34] CHEN Z, CHEN W, SMILEY C, et al. FinQA: A Dataset of Numerical Reasoning over Financial Data[C/OL]//MOENS M, HUANG X, SPECIA L, et al. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 7-11 November, 2021. Association for Computational Linguistics, 2021:

- 3697-3711. <https://doi.org/10.18653/v1/2021.emnlp-main.300>. DOI: 10.18653/V1/2021.EMNLP-MAIN.300.
- [35] LI X, ZHU Y, LIU S, et al. DyRRen: A Dynamic Retriever-Reranker-Generator Model for Numerical Reasoning over Tabular and Textual Data[C/OL]// WILLIAMS B, CHEN Y, NEVILLE J. Thirty-Seventh AAAI Conference on Artificial Intelligence, AAAI 2023, Thirty-Fifth Conference on Innovative Applications of Artificial Intelligence, IAAI 2023, Thirteenth Symposium on Educational Advances in Artificial Intelligence, EAAI 2023, Washington, DC, USA, February 7-14, 2023. AAAI Press, 2023: 13139-13147. <https://doi.org/10.1609/aaai.v37i11.26543>. DOI: 10.1609/AAAI.V37I11.26543.
- [36] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models[C/OL]// KOYEJO S, MOHAMED S, AGARWAL A, et al. Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022. 2022. http://papers.nips.cc/paper%5C_files/paper/2022/hash/9d5609613524ecf4f15af0f7b31abca4-Abstract-Conference.html.
- [37] CHEN W, MA X, WANG X, et al. Program of Thoughts Prompting: Disentangling Computation from Reasoning for Numerical Reasoning Tasks[J/OL]. Trans. Mach. Learn. Res., 2023, 2023. <https://openreview.net/forum?id=YfZ4ZPt8zd>.
- [38] TRAN H, YAO Z, YANG Z, et al. RARE: Retrieval-Augmented Reasoning Enhancement for Large Language Models[C/OL]// CHE W, NABENDE J, SHUTOVA E, et al. Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2025, Vienna, Austria, July 27 - August 1, 2025. Association for Computational Linguistics, 2025: 18305-18330. <https://aclanthology.org/2025.acl-long.896/>.

- [39] ZHAO W X, ZHOU K, LI J, et al. A Survey of Large Language Models[J/OL]. CoRR, 2023, abs/2303.18223. arXiv: 2303.18223. <https://doi.org/10.48550/arXiv.2303.18223>. DOI: 10.48550/ARXIV.2303.18223.
- [40] DING B, QIN C, ZHAO R, et al. Data Augmentation using LLMs: Data Perspectives, Learning Paradigms and Challenges[C/OL]//KU L, MARTINS A, SRIKUMAR V. Findings of ACL: Findings of the Association for Computational Linguistics, ACL 2024, Bangkok, Thailand and virtual meeting, August 11-16, 2024: vol. ACL 2024. Association for Computational Linguistics, 2024: 1679-1705. <https://doi.org/10.18653/v1/2024.findings-acl.97>. DOI: 10.18653/V1/2024.FINDINGS-ACL.97.
- [41] ZHENG C, SABOUR S, WEN J, et al. AugESC: Dialogue Augmentation with Large Language Models for Emotional Support Conversation[C/OL]//ROGERS A, BOYD-GRABER J L, OKAZAKI N. Findings of ACL: Findings of the Association for Computational Linguistics: ACL 2023, Toronto, Canada, July 9-14, 2023: vol. ACL 2023. Association for Computational Linguistics, 2023: 1552-1568. <https://doi.org/10.18653/v1/2023.findings-acl.99>. DOI: 10.18653/V1/2023.FINDINGS-ACL.99.
- [42] SHUM K, DIAO S, ZHANG T. Automatic Prompt Augmentation and Selection with Chain-of-Thought from Labeled Data[C/OL]//BOUAMOR H, PINO J, BALI K. Findings of ACL: Findings of the Association for Computational Linguistics: EMNLP 2023, Singapore, December 6-10, 2023: vol. EMNLP 2023. Association for Computational Linguistics, 2023: 12113-12139. <https://doi.org/10.18653/v1/2023.findings-emnlp.811>. DOI: 10.18653/V1/2023.FINDINGS-EMNLP.811.
- [43] SHAO Z, WANG P, ZHU Q, et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models[J/OL]. CoRR, 2024, abs/2402.03300. arXiv: 2402.03300. <https://doi.org/10.48550/arXiv.2402.03300>. DOI: 10.48550/ARXIV.2402.03300.

- [44] YU Q, ZHANG Z, ZHU R, et al. DAPO: An Open-Source LLM Reinforcement Learning System at Scale[J/OL]. CoRR, 2025, abs/2503.14476. arXiv: 2503.14476. <https://doi.org/10.48550/arXiv.2503.14476>. DOI: 10.48550/ARXIV.2503.14476.
- [45] RAFAILOV R, SHARMA A, MITCHELL E, et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model[C/OL]// OH A, NAUMANN T, GLOBERSON A, et al. Advances in Neural Information Processing Systems 36: Annual Conference on Neural Information Processing Systems 2023, NeurIPS 2023, New Orleans, LA, USA, December 10 - 16, 2023. 2023. http://papers.nips.cc/paper%5C_files/paper/2023/hash/a85b405ed65c6477a4fe8302b5e06ce7-Abstract-Conference.html.
- [46] YOU W, YIN S, ZHAO X, et al. MuMath: Multi-perspective Data Augmentation for Mathematical Reasoning in Large Language Models[C/OL]// DUH K, GÓMEZ-ADORNO H, BETHARD S. Findings of ACL: Findings of the Association for Computational Linguistics: NAACL 2024, Mexico City, Mexico, June 16-21, 2024: vol. NAACL 2024. Association for Computational Linguistics, 2024: 2932-2958. <https://doi.org/10.18653/v1/2024.findings-naacl.185>. DOI: 10.18653/V1/2024.FINDINGS-NAACL.185.
- [47] WEI J W, ZOU K. EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks[C/OL]// INUI K, JIANG J, NG V, et al. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, EMNLP-IJCNLP 2019, Hong Kong, China, November 3-7, 2019. Association for Computational Linguistics, 2019: 6381-6387. <https://doi.org/10.18653/v1/D19-1670>. DOI: 10.18653/V1/D19-1670.
- [48] OpenAI. GPT-4o System Card[J/OL]. CoRR, 2024, abs/2410.21276. arXiv: 2410.21276. <https://doi.org/10.48550/arXiv.2410.21276>. DOI: 10.48550/ARXIV.2410.21276.

- [49] ZHANG D, WU J, LEI J, et al. LLaMA-Berry: Pairwise Optimization for Olympiad-level Mathematical Reasoning via O1-like Monte Carlo Tree Search[C/OL]. //CHIRUZZO L, RITTER A, WANG L. Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL 2025 - Volume 1: Long Papers, Albuquerque, New Mexico, USA, April 29 - May 4, 2025. Association for Computational Linguistics, 2025: 7315-7337. <https://doi.org/10.18653/v1/2025.naacl-long.375>. DOI: 10.18653/V1/2025.NAACL-LONG.375.
- [50] ZHAO Y, YIN H, ZENG B, et al. Marco-o1: Towards Open Reasoning Models for Open-Ended Solutions[J/OL]. CoRR, 2024, abs/2411.14405. arXiv: 2411.14405. <https://doi.org/10.48550/arXiv.2411.14405>. DOI: 10.48550/ARXIV.2411.14405.
- [51] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning[J/OL]. CoRR, 2025, abs/2501.12948. arXiv: 2501.12948. <https://doi.org/10.48550/arXiv.2501.12948>. DOI: 10.48550/ARXIV.2501.12948.
- [52] ZHANG Z, ZHENG C, WU Y, et al. The Lessons of Developing Process Reward Models in Mathematical Reasoning[C/OL]. //CHE W, NABENDE J, SHUTOVA E, et al. Findings of ACL: Findings of the Association for Computational Linguistics, ACL 2025, Vienna, Austria, July 27 - August 1, 2025: vol. ACL 2025. Association for Computational Linguistics, 2025: 10495-10516. <https://aclanthology.org/2025.findings-acl.547/>.
- [53] YANG A, YANG B, ZHANG B, et al. Qwen2.5 Technical Report[J/OL]. CoRR, 2024, abs/2412.15115. arXiv: 2412.15115. <https://doi.org/10.48550/arXiv.2412.15115>. DOI: 10.48550/ARXIV.2412.15115.
- [54] GAO T, YAO X, CHEN D. SimCSE: Simple Contrastive Learning of Sentence Embeddings[C/OL]. //MOENS M, HUANG X, SPECIA L, et al. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing,

- EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 7-11 November, 2021. Association for Computational Linguistics, 2021: 6894-6910. <https://doi.org/10.18653/v1/2021.emnlp-main.552>. DOI: 10.18653/V1/2021.EMNLP-MAIN.552.
- [55] PATEL A, BHATTAMISHRA S, GOYAL N. Are NLP Models really able to Solve Simple Math Word Problems?[C/OL]//TOUTANOVA K, RUMSHISKY A, ZETTLEMOYER L, et al. Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2021, Online, June 6-11, 2021. Association for Computational Linguistics, 2021: 2080-2094. <https://doi.org/10.18653/v1/2021.naacl-main.168>. DOI: 10.18653/V1/2021.NAACL-MAIN.168.
- [56] CHEN Z, LIU T, Tongqing, et al. Advancing Mathematical Reasoning in Language Models: The Impact of Problem-Solving Data, Data Synthesis Methods, and Training Stages[C/OL]//The Thirteenth International Conference on Learning Representations, ICLR 2025, Singapore, April 24-28, 2025. OpenReview.net, 2025. <https://openreview.net/forum?id=GtpubstM1D>.
- [57] Baidu-ERNIE-Team. ERNIE 4.5 Technical Report[EB/OL]. 2025. https://ernie.baidu.com/blog/publication/ERNIE_Technical_Report.pdf.
- [58] Gemma-Team. Gemma 3n[J/OL]., 2025. <https://ai.google.dev/gemma/docs/gemma-3n>.
- [59] OpenAI. Gpt-oss-120b & gpt-oss-20b Model Card[J/OL]. CoRR, 2025, abs/2508.10925. arXiv: 2508.10925. <https://doi.org/10.48550/arXiv.2508.10925>. DOI: 10.48550/ARXIV.2508.10925.
- [60] YANG A, LI A, YANG B, et al. Qwen3 Technical Report[J/OL]. CoRR, 2025, abs/2505.09388. arXiv: 2505.09388. <https://doi.org/10.48550/arXiv.2505.09388>. DOI: 10.48550/ARXIV.2505.09388.

-
- [61] BALLON M, ALGABA A, GINIS V. The Relationship Between Reasoning and Performance in Large Language Models - o3 (mini) Thinks Harder, Not Longer[J/OL]. CoRR, 2025, abs/2502.15631. arXiv: 2502.15631. <https://doi.org/10.48550/arXiv.2502.15631>. DOI: 10.48550/ARXIV.2502.15631.
- [62] OpenAI. OpenAI GPT-5 System Card[J/OL]. CoRR, 2026, abs/2601.03267. arXiv: 2601.03267. <https://doi.org/10.48550/arXiv.2601.03267>. DOI: 10.48550/ARXIV.2601.03267.
- [63] CUI Y, CHE W, LIU T, et al. Pre-Training With Whole Word Masking for Chinese BERT[J/OL]. IEEE ACM Trans. Audio Speech Lang. Process., 2021, 29: 3504-3514. <https://doi.org/10.1109/TASLP.2021.3124365>. DOI: 10.1109/TASLP.2021.3124365.

附录 A 正文中涉及的提示词

PROMPT:

我需要你修改问题原有的解析，给出规范格式的新解析，要求如下：

1. 请逐步地进行思考, 如果有公式组合的部分需要一步步地拆分成基本公式进行求解
 2. 公式中的计算符号，如“+”、“-”、“×”、“/”和“^”不能省略
 3. 公式需要同时给出符号和有具体含义的两种形式，然后代入数值计算得出答案
 4. 涉及到单位换算的部分需要展示出来具体过程
 5. 使用“[]”标注公式中的变量，其中科学计数法形式的数字“ $a \times 10^b$ ”以及复杂的单位，需要使用“()”标注
 6. 如果有 latex 格式的公式，比如“ $\frac{Q_{\text{吸}}}{Q_{\text{放}}}$ ”需要改成正常算式的形式：“ $Q_{\text{吸}}/Q_{\text{放}}$ ”
 7. 解析开始如果给出“（解析可能存在错误）”表明给出的解析中可能存在错误
- 下面是一些例子：

input:

问题：在某次测试中该车匀速行驶时受到的阻力是车重的 0.02 倍，在 0.5h 内行驶了 28km 的路程，求：行驶的平均速度为多少？

解析：解：车辆在 0.5h 内行驶了 28km 的路程，所以行驶的平均速度为： $v=s/t=28\text{km}/0.5\text{h}=56\text{km/h}$ 。

output:

解：

原始解析比较清晰，下面将其转换为规范格式：

第一步，先计算平均速度： $v=s/t$

[平均速度]=[路程]/[时间]

算式 $=28\text{km}/0.5\text{h}=56\text{km/h}$

平均速度 $=56\text{km/h}$

答案 $=56\text{km/h}$

.....

下面是一个新的问题：

input: 问题

output:

图 A-1 规范化解析的提示词，用方框标明的为格式化参数，根据样例替换为具体内容

PROMPT:

我需要你帮我从给定的问题和解析中提取出解决问题使用到的公式，以及公式对应的参数表：

1. 请逐步地进行思考, 先对解析进行分析，然后生成提取结果，如果有公式组合的部分需要一步步地拆分成基本公式进行求解
2. 公式中所有的计算符号，如“+”、“-”、“×”、“/”和“^”不能省略
3. 公式中的每个变量需要使用“[]”标注出来，而且变量需要使用有意义的文字标识，尽量避免直接使用数值
4. 如果有 latex 格式的公式，比如“ $\frac{Q_{吸}}{Q_{放}}$ ”需要改成正常算式的形式：“[Q_吸]/[Q_放]”，算式中的单位换算部分不属于公式，不需要被提取
5. 参数表中的参数是公式中使用到的参数（参数名称要与公式中的参数一致），表格包括：概念、符号、数值、单位, 使用“|”分割单元格
6. 参数表中的数值和单位来自于问题本身以及解析计算的中间结果，如果参数进行了单位换算，参数表要给出原始的参数形式（没有进行单位换算）
7. 参数表中的参数如果没有单位或者是表示某个物体的数量，比如“3 盏灯”、“转了 8 圈”、“4 个人”等等，那么单位写入“null”
8. 提取结果中给出的公式和参数表中不需要任何额外的解释信息

下面是一些例子：

input:

问题：在某次测试中该车匀速行驶时受到的阻力是车重的 0.02 倍，在 0.5h 内行驶了 28km 的路程，求：行驶的平均速度为多少？

解析：解：原始解析比较清晰，下面将其转换为规范格式：

第一步，先计算平均速度： $v=s/t$

[平均速度]=[路程]/[时间]

算式 = $28\text{km}/0.5\text{h}=56\text{km/h}$

平均速度 = 56km/h

答案 = 56km/h

output:

提取分析：

1. 解析中的公式格式符合要求，计算符号没有省略，变量使用“[]”标注，而且变量使用有意义的文字标识
2. 计算过程中没有进行单位换算，参数可以直接提取

下面给出提取结果（单位换算部分不属于公式，不需要被提取；参数表中不需要额外解释信息）

提取结果： 1. 先计算平均速度，根据路程和时间的关系：

[平均速度]=[路程]/[时间]

参数表：

概念	符号	数值	单位
路程	s	28	km
时间	t	0.5	h
平均速度	v	56	km/h
.....			

下面是一个新的问题：

input: 问题

output:

图 A-2 参数提取的提示词，用方框标明的为格式化参数，根据样例替换为具体内容

PROMPT:

我需要你帮我解决问题中缺失参数的错误，我会给出问题以及缺失的参数，下面是错误纠正的要求：

1. 你需要先进行错误分析，分析如何修改来纠正错误，然后给出错误纠正部分，纠正其中的错误
2. 错误纠正部分不需要任何额外解释信息，错误纠正部分的格式为：“内容：修改前的内容-> 修改后的内容”，增加内容时”修改前的内容”为 null，删除内容时”修改后的内容”为 null
3. 如果问题中没有缺失的参数，那么向题目中增加缺失的参数；如果问题中的参数与缺失参数的含义相同但格式不同，那么在参数表中增加原始题目中的参数
4. 如果缺失参数可以由问题中的其他参数计算得到，那么给出相应的公式和参数表，不需要修改问题
5. 公式的格式为 “[缺失参数名]=[问题参数 1](+|-|×|/|^)[问题参数 2]”；参数表的格式为 “概念 | 符号 | 数值 | 单位”

下面是一些例子：

input:

问题：有一根烧红的铁钉，温度是 820°C ，质量是 $2\times 10^{-3}\text{kg}$ ，将它投入到某种液体中，该液体的初温是 10°C ，质量是 36.8g ，铁和液体的温度达到 20°C 后不再变化。不考虑周围环境的影响和热损失，铁的比热容为 $0.46\times 10^3\text{J}/(\text{kg}\cdot^{\circ}\text{C})$ 。
求：铁钉放出的热量。错误：问题缺少参数：铁的比热容 $=0.46\times 10^3\text{J}/(\text{kg}\cdot^{\circ}\text{C})$ ；铁钉的质量 $=2\times 10^{-3}\text{kg}$ ；

output:

错误分析：

1. 在问题中寻找 “铁的比热容 $=0.46\times 10^3\text{J}/(\text{kg}\cdot^{\circ}\text{C})$ ” 相关信息，可以找到 “铁的比热容为 $0.46\times 10^3\text{J}/(\text{kg}\cdot^{\circ}\text{C})$ ”，其中 “ $0.46\times 10^3\text{J}/(\text{kg}\cdot^{\circ}\text{C})$ ” 科学计数法格式存在问题：缺少了 “^”，应该将其改为 “铁的比热容为 $0.46\times 10^3\text{J}/(\text{kg}\cdot^{\circ}\text{C})$ ”
2. 在问题中寻找 “铁钉的质量 $=2\times 10^{-3}\text{kg}$ ” 相关信息，可以找到 “质量是 $2\times 10^{-3}\text{kg}$ ”，科学计数法的格式同样存在问题：缺少了 “^”，需要修改为 “质量是 $2\times 10^{-3}\text{kg}$ ”

错误纠正：

问题：铁的比热容为 $0.46\times 10^3\text{J}/(\text{kg}\cdot^{\circ}\text{C})$ -> $0.46\times 10^3\text{J}/(\text{kg}\cdot^{\circ}\text{C})$

问题：质量是 $2\times 10^{-3}\text{kg}$ -> 质量是 $2\times 10^{-3}\text{kg}$

.....

下面是一个新的问题：

input: 问题

output:

图 A-3 错误修正的提示词，用方框标明的为格式化参数，根据样例替换为具体内容

PROMPT:

下面我会给出两个公式，每个公式由参数和运算符号构成，[] 中的表示参数。你需要判断我给出的两个公式中对应参数表达含义是否相同，是否是同一个公式：

如果含义不相同，不是同一个公式，只需要回答不是；

如果各个参数含义相同，是同一个公式，则需要给出最终的公式，并且给出一个三行的表格来表示参数的对应关系，每个单元格内容是一个参数，前两行填写两个公式的参数，第三行填写统一后的公式参数。

下面是公式 1：

公式 1

下面是公式 2：

公式 2

通过表达含义判断，是否是同一个公式：

图 A-4 语义合并时的提示词，用方框标明的为格式化参数，根据样例替换为具体内容

PROMPT:

你是数学推理领域的专家。在解决问题之前，严格输出字符串“步骤”来表示每一步。如果在任何时候，已收集的信息足够直接解题，请以以下格式输出最终答案：“最终答案：答案”

以下是一些示例：

一件长袍需要 2 匝蓝色纤维和一半数量的白色纤维。总共需要多少匝纤维？

步骤 1：计算所需的白色纤维数量 [白色纤维数量] = [蓝色纤维数量] / 2 = 2 / 2 = 1

步骤 2：计算所需纤维总量 [纤维总量] = [蓝色纤维数量] + [白色纤维数量] = 2 + 1 = 3

最终答案：3

珍妮特养的鸭每天下 16 个蛋。她每天早晨早餐吃 3 个，用 4 个做松饼送给朋友。她把剩下的蛋每天在农贸市场卖，每个新鲜鸭蛋卖 2 美元。她每天在农贸市场能赚多少钱？

步骤 1：确定每天用掉的蛋总数。[消耗蛋数量] = [早餐消耗数量] + [松饼消耗数量] = 3 + 4 = 7

步骤 2：计算可供出售的剩余蛋数。[剩余蛋数量] = [总蛋数量] - [消耗蛋数量] = 16 - 7 = 9

步骤 3：计算卖剩余蛋的每日收入。[每日收入] = [剩余蛋数量] * [蛋的单价] = 9 * 2 = 18

最终答案：18

问题及已知步骤

图 A-5 蒙特卡洛树生成时的提示词，用方框标明的为格式化参数，根据样例替换为具体内容

PROMPT:

问题翻译

你是一个物理问题的英文翻译专家，我需要你将中文的问题翻译为英文形式，不需要给出任何解释信息，下面是具体的要求：

1. 给出的英文形式的问题中应该只有英文，不应出现中文，翻译时不要遗漏问题中的任何信息
2. 不需要给出其他任何解释信息

以下是你要翻译的问题：

问题

参数翻译

你是一个物理问题的英文翻译专家，我需要你将中文的参数内容翻译为英文形式，不需要给出任何解释信息，下面是具体的要求：

1. 给出的英文形式的参数内容中应该只有英文，不应出现中文，翻译时不要遗漏任何参数和其中的任何信息
2. 不需要给出其他任何解释信息

以下是你要翻译的参数内容：

参数 1

，

参数 2

……

参数 n

图 A-6 上方为问题翻译的提示词，下方为参数翻译的提示词。用方框标明的为格式化参数，根据样例替换为具体内容

PROMPT:

这是一个初中物理题目，根据问题给出计算的过程，让我们一步一步地地思考，在最后用“####”作为开始给出最终答案（一个数字）和答案的单位，将答案的数字和单位放在\boxed{} 中。

问题:

问题

答案:

图 A-7 零样本 CoT 方法提示词，用方框标明的为格式化参数，根据样例替换为具体内容

PROMPT:

编写 Python 代码分步解决以下问题。将最终数值结果存储在变量'answer' 中，将单位名称的字符串表示存储在变量'unit' 中。

问题:

问题

答案:

图 A-8 零样本 PoT 方法提示词，用方框标明的为格式化参数，根据样例替换为具体内容

PROMPT:

这是一个初中物理题目，根据问题给出计算的过程，让我们一步一步地思考，在最后用“###”作为开始给出最终答案（一个数字）和答案的单位，将答案的数字和单位放在\boxed{} 中。

可能用到的公式有: 公式 1, 公式 2 公式 n

问题: 问题

答案:

图 A-9 检索增强生成方法提示词，用方框标明的为格式化参数，根据样例替换为具体内容

PROMPT:

Input

这是一个初中物理题目，根据问题给出计算的过程，用公式表示。

问题: 问题

答案:

Output

公式 1, 公式 2 公式 n

图 A-10 公式生成模型训练提示词，用方框标明的为格式化参数，根据样例替换为具体内容

PROMPT:

Input

这是一个初中物理题目，找出对应概念的数值和单位。

问题: 问题

概念: 参数名称

数值:

Output

参数数值, 单位: 参数单位

图 A-11 参数识别模型训练提示词，用方框标明的为格式化参数，根据样例替换为具体内容

致 谢

首先，非常感谢我的导师程龚老师给予的帮助与指导。程老师在研究问题以及解决问题的思路给了我很多启发与思考，并为我研究生阶段的工作内容给予了许多支持。

其次，感谢我的家人和朋友。他们不仅在物质方面给予我足够的支持，还在精神方面给予我鼓励与帮助。

然后，感谢我在实验室中遇到的同学。我们不仅在学术研究上进行交流、互相探讨，更在生活中互相陪伴与帮助。

最后，我对在研究生阶段帮助过我的人表示诚挚的感谢和祝福！

